TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP.HCM

Khoa Công Nghệ Thông Tin

KHÓA LUẬN TỐT NGHIỆP

ỨNG DỤNG AI TRONG CÁ NHÂN HÓA TRẢI NGHIỆM MUA SẮM TRỰC TUYẾN

GIẢNG VIÊN HƯỚNG DẪN: ThS. Đặng Thị Kim Giao

SINH VIÊN THỰC HIỆN: Nguyễn Tấn Lộc – 22DH112033

Lê Hồ Thành Tài – 22DH113165

TP. HỒ CHÍ MINH, THÁNG 08 NĂM 2025

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP.HCM

Khoa Công Nghệ Thông Tin

KHÓA LUẬN TỐT NGHIỆP

ỨNG DỤNG AI TRONG CÁ NHÂN HÓA TRẢI NGHIỆM MUA SẮM TRỰC TUYẾN

GIẢNG VIÊN HƯỚNG DẪN: ThS. Đặng Thị Kim Giao

SINH VIÊN THỰC HIỆN: Nguyễn Tấn Lộc – 22DH112033

Lê Hồ Thành Tài – 22DH113165

TP. HỒ CHÍ MINH, THÁNG 08 NĂM 2025

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn sâu sắc đến cô Đặng Thị Kim Giao đã luôn hỗ trợ trong suốt quá trình nghiên cứu đề tài, triển khai xây dựng và hoàn thành đồ án tốt nghiệp này. Nhờ sự giải đáp kịp thời, đưa ra các phương hướng của cô trong lúc nhóm gặp các khó khăn mà nhóm có thêm nhiều cách giải quyết mang tính quyết định hơn cho đồ án. Em cũng xin cảm ơn Nhà Trường đã tạo điều kiện cho nhóm được thực hiện khóa luận, từ đó mà nhóm có thêm nhiều kinh nghiệm thực tiễn khi làm việc với Machine Learning – AI, giúp nhóm tiếp cận các công nghệ mới qua đó làm phong phú thêm kỹ năng chuyên môn. Thêm vào đó, các thành viên trong nhóm cũng gửi lời cảm ơn đến sự hỗ trợ thầm lặng từ gia đình cả về vật chất lẫn tinh thần, giúp nhóm lúc nào cũng cảm thấy thoải mái khi thực hiện đồ án. Xin chân thành cảm ơn.

LỜI CAM ĐOAN

Nhóm xin cam đoan những số liệu và kết quả nghiên cứu được nêu ra trong đồ án ỨNG DỤNG AI TRONG CÁ NHÂN HÓA TRẢI NGHIỆM MUA SẮM TRỰC TUYẾN là hoàn toàn trung thực. Cam kết không xuất hiện tình trạng sao chép hay sử dụng kết quả nghiên cứu của một công trình nào khác đã được công bố trước đây. Những tài liệu tham khảo được trích dẫn một cách đầy đủ, đồng thời ghi rõ ràng về nguồn gốc theo quy định của nhà trường.

Mục lục

Mục lục i

Bảng từ viết tắt v

Danh mục bảng vi

Danh mục hình ảnh vii

Chương 1 GIỚI THIỆU 1

1.1 Lý do chọn đề tài 1

1.2 Mục tiêu nghiên cứu 2

1.3 Phạm vi nghiên cứu 3

1.4 Phương pháp tiếp cận 4

1.5 Cấu trúc báo cáo 6

Chương 2 CƠ SỞ LÝ THUYẾT 7

2.1 Tổng quan công nghệ sử dụng 7

2.1.1 Trí Tuệ Nhân Tạo (AI) và Học Máy (Machine Learning) 7

2.1.2 Các thuật toán và mô hình sử dụng trong đề tài 8

2.1.3 Công nghệ và công cụ hỗ trợ phát triển 9

2.2 Tổng quan về lĩnh vực ứng dụng 9

2.2.1 Bối cảnh hiện tại 9

2.2.2 Vấn đề chính 10

2.2.3 Vai trò của AI và hệ thống gợi ý 10

2.2.4 Mục tiêu áp dụng trong đề tài 11

2.3 Các nghiên cứu trước có liên quan 11

2.4 Khoảng trống nghiên cứu 12

2.4.1 Hạn chế trong việc chỉ sử dụng một loại dữ liệu đầu vào 12
2.4.2 Thiếu các mô hình tích hợp nhiều nguồn dữ liệu (hybrid) trong môi trường nhỏ gọn 12
2.4.3 Thiếu tiếp cận đơn giản, khả thi trong việc tích hợp hành vi người dùng phi rating 13
Chương 3 PHÂN TÍCH YÊU CẦU VÀ THIẾT KẾ HỆ THỐNG 14
3.1 Phân tích yêu cầu 14
3.1.1 Yêu cầu chức năng 14
3.1.2 Yêu cầu phi chức năng 15
3.1.3 Yêu cầu về dữ liệu 15
3.2 Mô hình chức năng 16
3.2.1 Use Case Diagram Tổng Quát 16
3.2.2 Use Case Diagram Quản Lý Người Dùng 17
3.2.3 Use Case Diagram Quản Lý Sản Phẩm 18
3.2.4 Use Case Diagram Quản Lý Danh Mục 19
3.2.5 Use Case Diagram Quản Lý Nhãn Hàng 20
3.2.6 Use Case Diagram Quản Lý Nhãn 21
3.2.7 Use Case Diagram Quản Lý Đơn Hàng 22
3.2.8 Use Case Diagram Tương Tác Trang Chủ 23
3.2.9 Use Case Diagram Quản Lý Giỏ Hàng 24
3.2.10 Use Case Diagram Đặt Mua 25
3.3 Cơ sở dữ liệu 26
3.3.1 ERD Tổng Quát 26
3.3.2 Bảng User 26

3.3.3 Bảng Item 27
3.3.4 Bảng Category 28
3.3.5 Bảng Brand 28
3.3.6 Bảng Tag 28
3.3.7 Bảng Order 29
3.3.8 Bảng Rating 29
3.3.9 Bảng UserHistory 30
3.4 Kiến trúc hệ thống 31
3.5 Luồng xử lý chính 32
3.5.1 Dữ liệu đầu vào 33
3.5.2 Quá trình xử lý 33
3.5.3 Đầu ra của hệ thống 34
Chương 4 XÂY DỰNG MÔ HÌNH AI 35
4.1 Thu thập và xử lý dữ liệu 35
4.1.1 Nguồn dữ liệu 35
4.1.2 Tiền xử lý dữ liệu 36
4.1.3 Phân tích dữ liệu 37
4.2 Mô hình AI và huấn luyện 39
4.2.1 Chọn mô hình 39
4.2.2 Huấn luyện mô hình 41
4.3 Đánh giá mô hình 42
4.3.1 Các chỉ số đánh giá sử dụng 42
4.3.2 Kết quả đánh giá 43
4.3.3 So sánh mô hình 45

4.4 Triển khai thử nghiệm 45
4.5 Kết quả và phân tích 48
4.5.1 Kết quả đầu ra 49
4.5.2 Đánh giá hiệu quả 49
4.5.3 Phân tích lỗi và cải tiến 51
4.6 Giao diện ứng dụng 53
4.6.1 Người dùng 53
4.6.2 Người dùng quản trị 59
Chương 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 62
5.1.1 Tóm tắt kết quả đạt được 62
5.1.2 Hạn chế của nghiên cứu 62
5.1.3 Hướng phát triển 63
Tài liệu tham khảo 64

Bảng từ viết tắt

STT	Từ viết tắt	Mô tả
1	ML	Machine Learning
2	CF	Collaborative Filtering
3	CSDL	Cơ Sở Dữ Liệu
4	AI	Artificial Intelligence
5	TMĐT	Thương Mại Điện Tử
6	NCF	Neural Collaborative Filtering
7	CRUD	Create Read Update Delete

Danh mục bảng

Bảng 1. Thống kê Mô hình và dữ liệu sử dụng.....2

Bảng 2. Bảng User 26

Bảng 3. Bảng Item.....27

Bảng 4. Bảng Category 28

Bảng 5. Bảng Brand 28

Bảng 6. Bảng Tag.....28

Bảng 7. Bảng Order.....29

Bảng 8. Bảng Rating 29

Bảng 9. Bảng UserHistory 30

Bảng 10. Kết Quả Đầu Ra.....49

Bảng 11. Đánh Giá Hiệu Quả 50

Danh mục hình ảnh

Hình 1 Use Case Diagram Tổng Quát 16
Hình 2 Use Case Diagram Quản Lý Người Dùng 17
Hình 3 Use Case Diagram Quản Lý Sản Phẩm 18
Hình 4 Use Case Diagram Quản Lý Danh Mục.....19
Hình 5 Use Case Diagram Quản Lý Nhãn Hàng 20
Hình 6 Use Case Diagram Quản Lý Nhãn.....21
Hình 7 Use Case Diagram Quản Lý Đơn Hàng.....22
Hình 8 Use Case Diagram Tương Tác Trang Chủ.....23
Hình 9 Use Case Diagram Quản Lý Giỏ Hàng.....24
Hình 10 Use Case Diagram Đặt Mua.....25
Hình 11 ERD Tổng Quát.....26
Hình 12. Kiến Trúc Tổng Thể Hệ Thống.....31
Hình 13. Luồng Xử Lý Của Hệ Thống 32
Hình 14. Histogram Phân Bố Lượt Tương Tác Người Dùng 38
Hình 15. Pie Chart Thể Hiện Lượng Tương Tác Vào Ngày 15/07/2025.....39
Hình 16. Demo gợi ý bằng Collaborative Filtering (Surprise SVD) 46
Hình 17. Demo ý bằng Content-Based Filtering dựa trên metadata sản phẩm.....47
Hình 18. Demo ý bằng Content-Based Filtering dựa trên hành vi người dùng.....48
Hình 19. Giao Diện Trang Chủ.....53
Hình 20. Giao Diện Đăng Nhập Dành Cho Người Dùng 54
Hình 21. Giao Diện Đăng Ký Dành Cho Người Dùng.....54

Hình 22. Giao Diện Xem Chi Tiết Sản Phẩm 55
Hình 23. Giao Diện Giỏ Hàng.....55
Hình 24. Giao Diện Xác Nhận Thanh Toán.....56
Hình 25. Giao Diện Đặt Hàng Thành Công.....56
Hình 26. Giao Diện Tìm Kiếm Sản Phẩm 57
Hình 27. Giao Diện Đơn Hàng Đã Mua 57
Hình 28. Giao Diện Trang Về Chúng Tôi.....58
Hình 29. Giao Diện Trang Tin Tức.....58
Hình 30. Giao Diện Dashboard Cho Admin 59
Hình 31. Giao Diện Quản Lý Sản Phẩm.....59
Hình 32. Giao Diện Quản Lý Người Dùng.....60
Hình 33. Giao Diện Quản Lý Danh Mục 60
Hình 34. Giao Diện Thống Kê Doanh Thu 61

Chương 1 GIỚI THIỆU

1.1 Lý do chọn đề tài

Trong thời đại thương mại điện tử phát triển mạnh mẽ như hiện nay, các website bán hàng đã trở thành một phần thiết yếu đối với cả doanh nghiệp và người tiêu dùng. Những nền tảng này không chỉ hỗ trợ hiệu quả trong việc quản lý sản phẩm, đơn hàng mà còn đóng vai trò quan trọng trong việc tạo điều kiện thuận lợi cho các giao dịch trực tuyến diễn ra nhanh chóng, tiện lợi. Một trong những yếu tố then chốt góp phần nâng cao trải nghiệm người dùng trên các nền tảng thương mại điện tử chính là hệ thống gợi ý sản phẩm – một ứng dụng tiêu biểu của trí tuệ nhân tạo. Thông qua việc phân tích thói quen, hành vi mua sắm và sở thích cá nhân, các hệ thống này có thể đưa ra những đề xuất phù hợp với từng người dùng, từ đó cá nhân hóa trải nghiệm và nâng cao mức độ hài lòng.

Tuy nhiên, đối với các doanh nghiệp, việc tạo ra trải nghiệm mua sắm cá nhân hóa cho hàng triệu khách hàng với nhu cầu và sở thích khác nhau vẫn là một thách thức lớn. Nhiều hệ thống hiện nay vẫn chưa tận dụng hiệu quả dữ liệu người dùng, dẫn đến các gợi ý thiếu chính xác, ảnh hưởng đến tỷ lệ chuyển đổi và hiệu quả kinh doanh. Ở phía người tiêu dùng, khi phải đối mặt với một số lượng sản phẩm quá lớn mà thiếu công cụ hỗ trợ phù hợp, họ dễ rơi vào trạng thái bối rối, mất thời gian tìm kiếm và giảm hứng thú với quá trình mua sắm.

Từ góc nhìn cá nhân, nhóm chúng em nhận thấy đây là cơ hội lý tưởng để ứng dụng các kiến thức về trí tuệ nhân tạo và học máy vào một bài toán thực tiễn, đồng thời góp phần giải quyết một vấn đề cụ thể trong lĩnh vực thương mại điện tử hiện nay.

Để giải quyết bài toán này, nhóm chúng em đã lựa chọn tích hợp một hệ thống gợi ý sản phẩm thông minh vào website bán hàng, sử dụng thư viện SURPRISE trong ngôn ngữ Python.

1.2 Mục tiêu nghiên cứu

Đề tài hướng đến các mục tiêu chính sau:

- Xây dựng hệ thống gợi ý sản phẩm tích hợp vào website TMĐT đơn giản (SnapBuyWeb).
- Ứng dụng các thuật toán học máy để đưa ra các đề xuất phù hợp cho người dùng dựa trên:
  - Đánh giá sản phẩm (ratings)
  - Thông tin sản phẩm (category, brand)
  - Hành vi tương tác (clicks, views)
- So sánh và đánh giá hiệu quả giữa các mô hình gợi ý được triển khai.
- Tối ưu luồng xử lý và tích hợp mô hình ML vào hệ thống thực tế với dữ liệu mô phỏng.

Bảng 1. Thống kê Mô hình và dữ liệu sử dụng

STT	Mô hình sử dụng	Dữ liệu đầu vào	Thuật toán	Mục đích chính
1	Collaborative Filtering (Surprise)	Rating phim từ MovieLens	SVD	Gợi ý sản phẩm dựa trên đánh giá
2	Content-Based Filtering (Sản phẩm)	Danh mục, nhãn hàng của các sản phẩm giả lập	TF-IDF + Cosine	Gợi ý sản phẩm tương tự nội dung
3	Content-Based Filtering (Hành vi người dùng)	Lượt xem sản phẩm từ bảng user_history	TF-IDF + Cosine	Gợi ý dựa vào lịch sử tương tác

1.3 Phạm vi nghiên cứu

Chức năng chính của hệ thống

- Hệ thống chỉ tập trung vào phần gợi ý sản phẩm cho người dùng dựa trên các dữ liệu đã được ghi lại như lượt ratings, lượt xem dành cho một sản phẩm.

Chức năng cơ bản & cần thiết

- Đăng ký/Đăng nhập dành cho người dùng
- Đăng nhập cho người quản trị hệ thống
- Người quản trị hệ thống:
  - Quản lý người dùng
  - Quản lý sản phẩm
  - Quản lý danh mục
  - Quản lý thương hiệu
  - Quản lý đơn hàng
  - Thống kê doanh thu
- Người dùng:
  - Tương tác trang chủ
  - Quản lý giỏ hàng
  - Đặt mua/Thanh toán
  - Xác nhận giao hàng/Đánh giá
- Đăng xuất

Dữ liệu sử dụng

- Sử dụng dữ liệu mô phỏng từ:
  - MovieLens 100k
  - Hành vi: mô phỏng hành vi xem sản phẩm từ 30 người dùng

    - Sản phẩm: được giả lập dựa trên các trường như danh mục, nhãn hàng, không phải dữ liệu thật.
- Không thu thập dữ liệu thực tế từ hệ thống TMĐT có thật.

Công nghệ AI/ML sử dụng

- Chỉ sử dụng 3 mô hình
    - Collaborative Filtering (Surprise – SVD).
    - Content-Based Filtering (thuộc tính sản phẩm).
    - Content-Based Filtering (hành vi người dùng).
- Không sử dụng các mô hình deep learning phức tạp (neural network, BERT, LSTM,…) do giới hạn về thời gian và tài nguyên.

Thời gian & phạm vi thử nghiệm

- Phạm vi thử nghiệm chỉ áp dụng cho 30 người dùng mô phỏng.
- Thời gian triển khai: giới hạn trong học kỳ III.
- Kết quả đánh giá chỉ mang tính tương đối nên không mang tính thương mại và triển khai thật.

Đối tượng người dùng mà hệ thống muốn tiếp cận

- Người dùng giả lập là người dùng phổ thông của một website TMĐT giả định (SnapBuyWeb).
- Không phục vụ cho bất kỳ một doanh nghiệp cụ thể hay nhóm người dùng chuyên biệt nào.

1.4 Phương pháp tiếp cận

Cần áp dụng các phương pháp kỹ thuật chính này để đề tài đạt mục tiêu đề ra ban đầu:

- Học máy (Machine Learning): Áp dụng các thuật toán học máy truyền thống như Collaborative Filtering dựa trên ma trận user-item-rating và Content-Based Filtering dựa trên các đặc trưng của một sản phẩm và hành vi tương tác của người dùng đối với sản phẩm.
- Tiền xử lý dữ liệu:
  - Thu thập dữ liệu từ các nguồn Open - source như tập MovieLens đồng thời mô phỏng dữ liệu hành vi người dùng trong hệ thống.
  - Mục đích để làm sạch, chuẩn hóa và biểu diễn đặc trưng (One-Hot Encoding, TF-IDF).
- Xây dựng mô hình:
  - Huấn luyện mô hình Collaborative Filtering trên tập dữ liệu rating.
  - Xây dựng mô hình Content-Based Filtering dựa trên đặc trưng sản phẩm (danh mục, nhãn hàng) và lịch sử tương tác của người dùng đối với sản phẩm.
- Đánh giá kết quả:
  - Sử dụng các chỉ số đánh giá như RMSE, Precision@K, Recall@K để so sánh hiệu quả giữa các mô hình.
  - Đánh giá hiệu quả mô hình khi tích hợp vào hệ thống thực tế SnapBuyWeb.

1.5 Cấu trúc báo cáo

Chương 1: Giới thiệu đề tài và mục tiêu nghiên cứu.

Trình bày lý do chọn đề tài, mục tiêu, phạm vi nghiên cứu, phương pháp tiếp cận và cấu trúc tổng thể của báo cáo.

Chương 2: Trình bày cơ sở lý thuyết và tổng quan nghiên cứu liên quan.

Trình bày các khái niệm về hệ thống gợi ý, các mô hình học máy được sử dụng, các thuật toán liên quan cũng như các công nghệ và công cụ hỗ trợ quá trình phát triển.

Chương 3: Phân tích yêu cầu và thiết kế hệ thống.

Mô tả kiến trúc tổng thể, phân tích yêu cầu từ người dùng, thiết kế cơ sở dữ liệu cho hệ thống SnapBuyWeb.

Chương 4: Thu thập và xử lý dữ liệu.

Giới thiệu nguồn dữ liệu, quy trình tiền xử lý, chuyển đổi dữ liệu để phục vụ huấn luyện mô hình. Đồng thời trình bày quá trình huấn luyện các mô hình, tích hợp vào hệ thống.

Chương 5: Đánh giá kết quả và kết luận

Tổng hợp kết quả tổng thể thu được, nêu ưu nhược điểm, kết luận và đề xuất hướng phát triển trong tương lai.

Chương 2 CƠ SỞ LÝ THUYẾT

2.1 Tổng quan công nghệ sử dụng

2.1.1 Trí Tuệ Nhân Tạo (AI) và Học Máy (Machine Learning)

Trí tuệ nhân tạo là khả năng của các hệ thống máy tính thực hiện các nhiệm vụ liên quan đến trí thông minh của con người như học tập, suy luận, giải quyết vấn đề và đưa ra quyết định. Đây là một lĩnh vực thuộc Khoa Học Máy Tính, nhằm nghiên cứu và phát triển thông qua các phương pháp để giúp máy móc có khả năng nhận thức môi trường xung quanh, học tập và trí tuệ để thực hiện một vài hành động qua đó tối ưu hóa khả năng đạt được các mục tiêu đã định.

Các ứng dụng nổi bật của AI trong cuộc sống như: Công cụ tìm kiếm Google; hệ thống đề xuất được sử dụng bởi YouTube, Amazon, Tiktok; trợ lý ảo Google Assistant, Siri, Alexa; xe tự hành như Tesla, Waymo. Hay cả trong khả năng phân tích chiến lược được thể hiện qua việc AI chơi cờ vây và cờ vua.

Học máy là một lĩnh vực của Trí tuệ nhân tạo, liên quan đến việc nghiên cứu và xây dựng các kỹ thuật cho phép các hệ thống tự "học" tự động từ những dữ liệu để giải quyết vấn đề cụ thể. Các thuật toán học máy được xây dựng trên dữ liệu mẫu hay còn được gọi là dữ liệu huấn luyện nhằm đưa ra các dự đoán hoặc quyết định mà không cần được lập trình chi tiết về việc đưa ra dự đoán hoặc quyết định này.

Phân loại học máy:

- Học có giám sát (Supervised Learning)
- Học không giám sát (Unsupervised Learning)
- Học tăng cường (Reinforcement Learning)

Chuyên sâu hơn ta có: Deep Learning là một phần mở rộng của Học máy, sử dụng mạng nơ-ron đa tầng để mô hình hóa các dữ liệu phức tạp.

2.1.2 Các thuật toán và mô hình sử dụng trong đề tài

Mô hình Collaborative Filtering (CF) dựa trên lượt rating mà một người dùng đánh giá cho sản phẩm sau khi mua hàng:

- Dựa trên thuật toán SVD (Singular Value Decomposition) dùng để khai thác ma trận user-item-rating nhằm dự đoán các đánh giá còn thiếu và từ đó gợi ý sản phẩm phù hợp.
  - Ưu điểm:
    - Giúp giảm chiều dữ liệu, lọc bỏ nhiễu.
    - Tăng khả năng dự đoán chính xác các đánh giá thiếu.
    - Dễ dàng triển khai với thư viện Surprise, hỗ trợ tối ưu tham số.
  - Hạn chế:
    - Phụ thuộc vào dữ liệu rating có sẵn, không giải quyết tốt vấn đề người dùng mới.
    - Cần điều chỉnh tham số để tránh quá khớp hoặc thiếu khớp.

Mô hình Content-Based Filtering dựa trên thuộc tính sản phẩm.

- Mô hình dựa trên việc so sánh các đặc trưng của một sản phẩm để đề xuất các mặt hàng tương tự.
  - Ưu điểm:
    - Không phụ thuộc vào rating người dùng
    - Giải quyết tốt vấn đề cold-start với sản phẩm mới
  - Nhược điểm:
    - Phụ thuộc vào chất lượng đặc trưng sản phẩm

        - Không khai thác đa dạng và sự thay đổi hành vi của người dùng

Mô hình Content-Based Filtering dựa trên hành vi người dùng.

- Tận dụng dữ liệu lịch sử tương tác của người dùng như lượt xem, click để xây dựng hồ sơ hành vi.
    - Ưu điểm:
        - Phản ánh được thói quen và sở thích cá nhân của người dùng
        - Có thể cập nhật liên tục theo hành vi mới
    - Nhược điểm:
        - Dữ liệu hành vi có thể nhiễu hoặc không đầy đủ
        - Phức tạp trong việc xử lý dữ liệu lớn hoặc đa dạng hành vi

2.1.3 Công nghệ và công cụ hỗ trợ phát triển

- Ngôn ngữ lập trình Python
- Flask framework để xây dựng hệ thống web
- Thư viện Surprise cho Collaborative Filtering
- Scikit-learn cho xử lý đặc trưng và tính toán similarity
- SQLite làm hệ quản trị cơ sở dữ liệu nhẹ
- Các công cụ hỗ trợ khác như Pandas, NumPy

2.2 Tổng quan về lĩnh vực ứng dụng

2.2.1 Bối cảnh hiện tại

Sau đại dịch COVID-19, sự bùng nổ của TMĐT là không thể bàn cãi, điều này dẫn đến việc người tiêu dùng cần các nơi uy tín, tiện lợi để phục vụ nhu cầu mua sắm của bản thân.

Các sàn TMĐT như Shopee, Tiki, Lazada,… có hàng triệu sản phẩm nhưng không có những gợi ý mua hàng phù hợp từ đó tạo ra trải nghiệm mua sắm chưa hài lòng.

Trong môi trường cạnh tranh cao, việc đưa đúng sản phẩm đến đúng người dùng vào đúng thời điểm là yếu tố then chốt giúp tăng doanh thu và giữ chân khách hàng.

2.2.2 Vấn đề chính

Người dùng khó tìm thấy sản phẩm phù hợp giữa kho hàng triệu sản phẩm → dễ bỏ qua sản phẩm tiềm năng.

Trải nghiệm mua sắm trở nên kém hiệu quả nếu hệ thống không hiểu được sở thích cá nhân của người dùng.

Doanh nghiệp bỏ lỡ cơ hội bán hàng nếu không có hệ thống cá nhân hóa sản phẩm phù hợp.

2.2.3 Vai trò của AI và hệ thống gợi ý

Hệ thống gợi ý (Recommender System) là một ứng dụng AI quan trọng, giúp cá nhân hóa trải nghiệm người dùng.

Nhờ vào các mô hình học máy (Machine Learning), hệ thống có thể phân tích hành vi người dùng, lịch sử mua hàng, hoặc đặc điểm sản phẩm để dự đoán sở thích và đưa ra gợi ý phù hợp.

Gợi ý sản phẩm hiệu quả giúp:

- Tăng tỷ lệ chuyển đổi (conversion rate).
- Tăng doanh thu trung bình trên mỗi khách hàng (AOV).
- Tăng thời gian người dùng tương tác với nền tảng.

2.2.4 Mục tiêu áp dụng trong đề tài

Xây dựng một mô hình gợi ý sản phẩm phù hợp với môi trường TMĐT nhỏ/mô phỏng.

Tận dụng dữ liệu hành vi và đặc điểm sản phẩm để cá nhân hóa trải nghiệm người dùng.

Làm nền tảng cho các hệ thống quy mô lớn hơn hoặc triển khai thực tế trong tương lai.

2.3 Các nghiên cứu trước có liên quan

Koren, Bell & Volinsky (2009)

Ý tưởng chính: Phát triển kỹ thuật ma trận nhân tử (Matrix Factorization) cho hệ thống gợi ý, đưa vào áp dụng thành công trong Cuộc thi Netflix Prize.

Hạn chế: Mô hình chỉ dựa vào dữ liệu rating, không sử dụng thông tin nội dung sản phẩm hay hành vi người dùng, gặp hạn chế với cold-start scenario.

He et al. (2017) – Neural Collaborative Filtering (NCF)

Nội dung: Sử dụng mạng nơ-ron để thay thế tích vô hướng trong ma trận latent để học được tương tác phi tuyến giữa user và item.

Hạn chế: Yêu cầu khối lượng dữ liệu lớn và tài nguyên tính toán cao, không phù hợp với hệ thống nhỏ hoặc môi trường sinh viên.

Zhang et al. (2017–2019) – Tổng quan về recommender system

Nội dung: Survey toàn diện các phương pháp từ truyền thống đến ứng dụng deep learning (NCF, review-based, hybrid), chỉ rõ xu hướng và lợi ích của từng hướng.

Hạn chế: Mặc dù rất hữu ích để hiểu toàn cảnh, nhưng các mô hình nhiều tầng thường khó triển khai trong đồ án với dữ liệu mô phỏng và hạn chế về thời gian.

2.4 Khoảng trống nghiên cứu

2.4.1 Hạn chế trong việc chỉ sử dụng một loại dữ liệu đầu vào

Phần lớn các mô hình như SVD hoặc NCF chủ yếu dựa vào lượt đánh giá (ratings) của người dùng, trong khi đó các yếu tố như thông tin mô tả sản phẩm (tên, danh mục, nhãn hàng) hay hành vi người dùng không có rating (click, xem) lại chưa được tận dụng đầy đủ.

2.4.2 Thiếu các mô hình tích hợp nhiều nguồn dữ liệu (hybrid) trong môi trường nhỏ gọn

Nhiều nghiên cứu sử dụng các mô hình phức tạp (deep learning, attention) để kết hợp thông tin đa dạng, tuy nhiên các mô hình này đòi hỏi tài nguyên lớn và khó triển khai trong môi trường hạn chế như dự án sinh viên.

2.4.3 Thiếu tiếp cận đơn giản, khả thi trong việc tích hợp hành vi người dùng phi rating

Việc tận dụng các tương tác như xem sản phẩm, click, thêm vào giỏ hàng… để cải thiện gợi ý vẫn chưa được áp dụng phổ biến ở các hệ thống đơn giản (thường chỉ dùng rating hoặc mua hàng).

Chương 3 PHÂN TÍCH YÊU CẦU VÀ THIẾT KẾ HỆ THỐNG

3.1 Phân tích yêu cầu

3.1.1 Yêu cầu chức năng

Đăng ký/Đăng nhập

- Đăng ký tài khoản cho người dùng.
- Đăng nhập cho người dùng/người quản trị hệ thống.

Quản lý người dùng

- Quản lý trạng thái tài khoản người dùng.

Hiển thị danh sách sản phẩm

- Lọc sản phẩm theo danh mục nổi bật.
- Tìm kiếm sản phẩm theo từ khóa.

Hệ thống gợi ý

- Gợi ý sản phẩm dựa trên lượt đánh giá.
- Gợi ý sản phẩm dựa theo nội dung.
- Gợi ý dựa trên hành vi người dùng.

Ghi nhận hành vi người dùng

- Lưu lại các hành động như click vào sản phẩm, lượt xem.

Quản trị

- Thêm/sửa/xóa sản phẩm, danh mục, nhãn hàng.

3.1.2 Yêu cầu phi chức năng

Hiệu năng

- Gợi ý được tạo nhanh chóng (tối ưu tính toán).
- Không gây chậm trễ khi người dùng truy cập.

Tính mở rộng

- Có thể thêm sản phẩm mới, người dùng mới mà không cần huấn luyện lại toàn bộ.

Khả năng triển khai

- Hệ thống triển khai được bằng Flask, dễ bảo trì, dễ test.
- Không yêu cầu GPU hay tài nguyên phần cứng cao cấp.

Tính khả dụng

- Giao diện đơn giản, dễ thao tác.
- Hiển thị gợi ý rõ ràng, phù hợp với người dùng phổ thông.

3.1.3 Yêu cầu về dữ liệu

Dữ liệu đầu vào

- Bảng ratings: user_id, item_id, rating
- Bảng items: id, name, category_id, brand_id
- Bảng user_history: user_id, item_id, interaction_type, timestamp

Dữ liệu đầu ra

- Danh sách sản phẩm gợi ý cho từng người dùng.
- Gợi ý được lọc theo từng mô hình hoặc tích hợp.

3.2 Mô hình chức năng

3.2.1 Use Case Diagram Tổng Quát

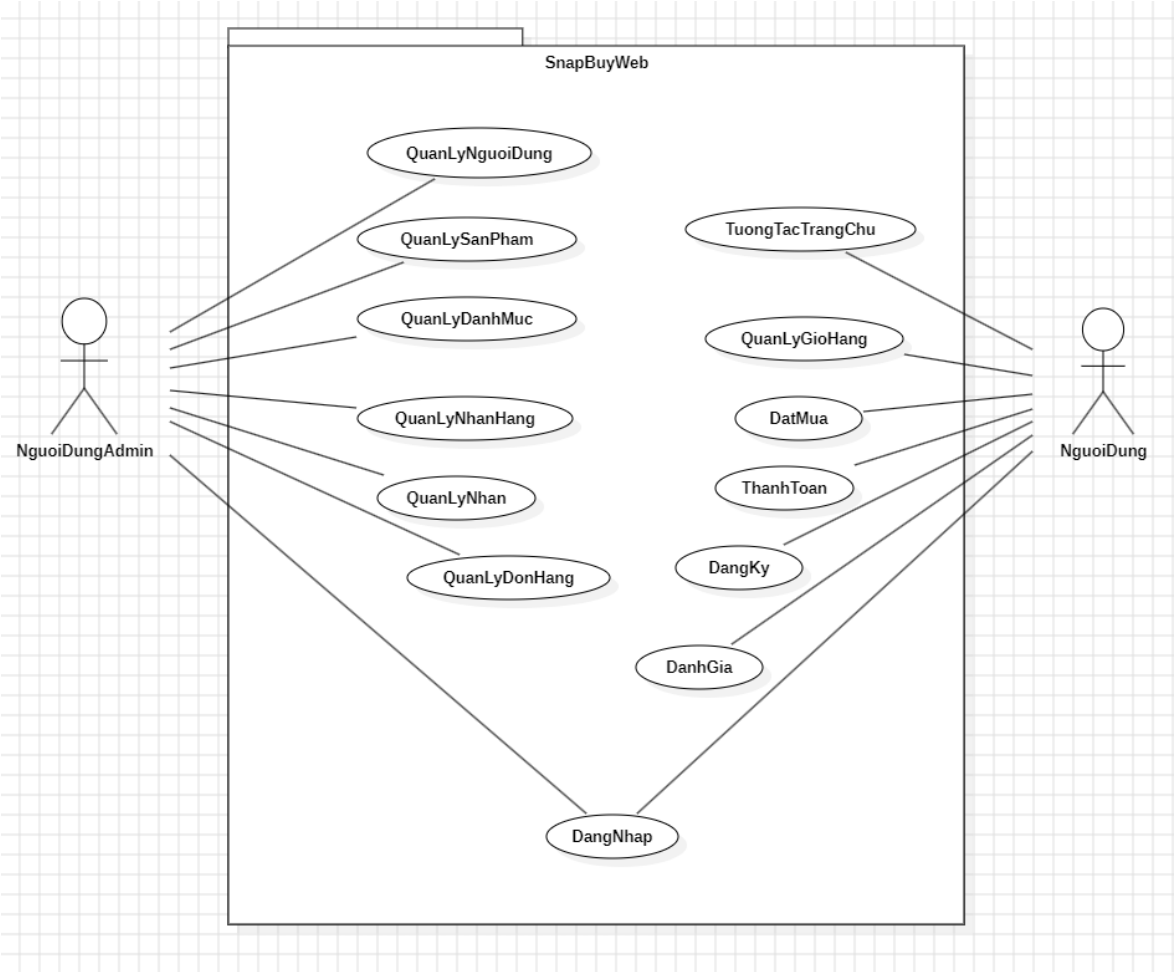

Hình 1 Use Case Diagram Tổng Quát

3.2.2 Use Case Diagram Quản Lý Người Dùng

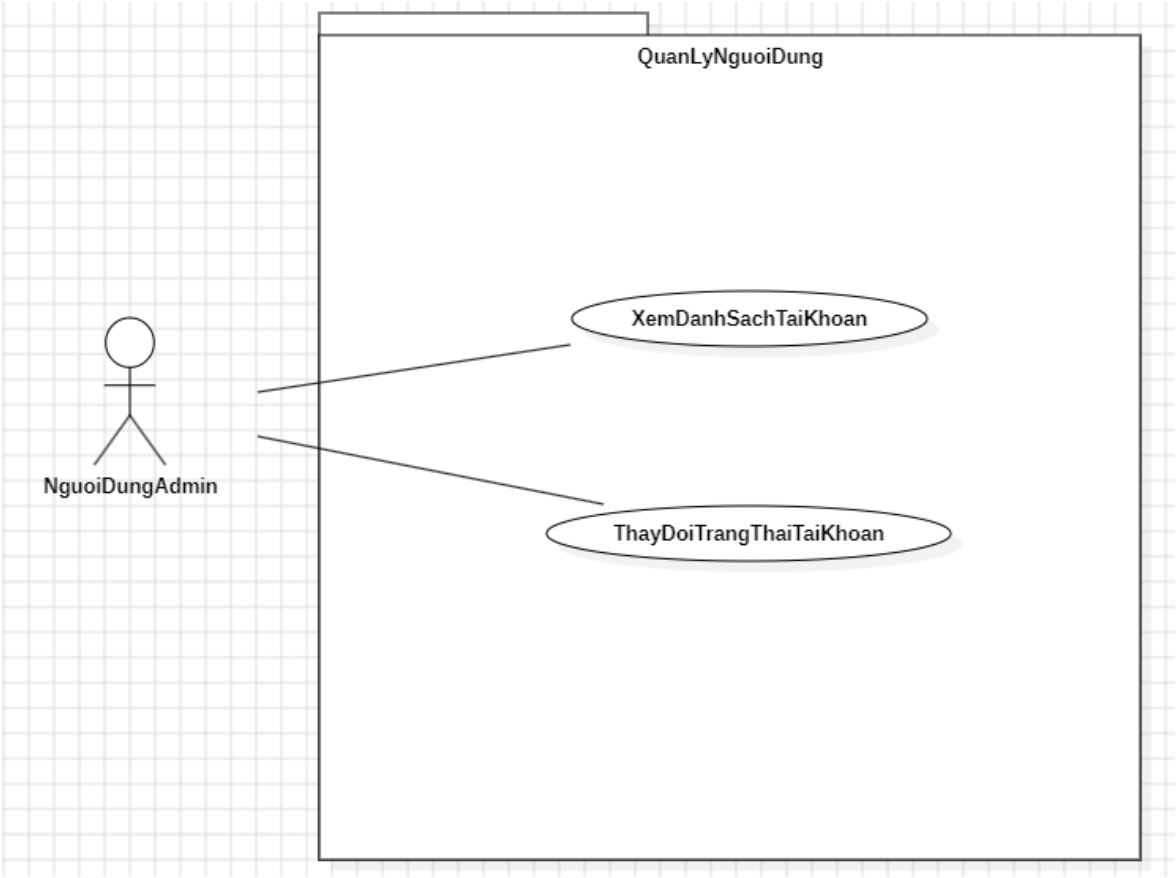

Hình 2 Use Case Diagram Quản Lý Người Dùng

3.2.3 Use Case Diagram Quản Lý Sản Phẩm

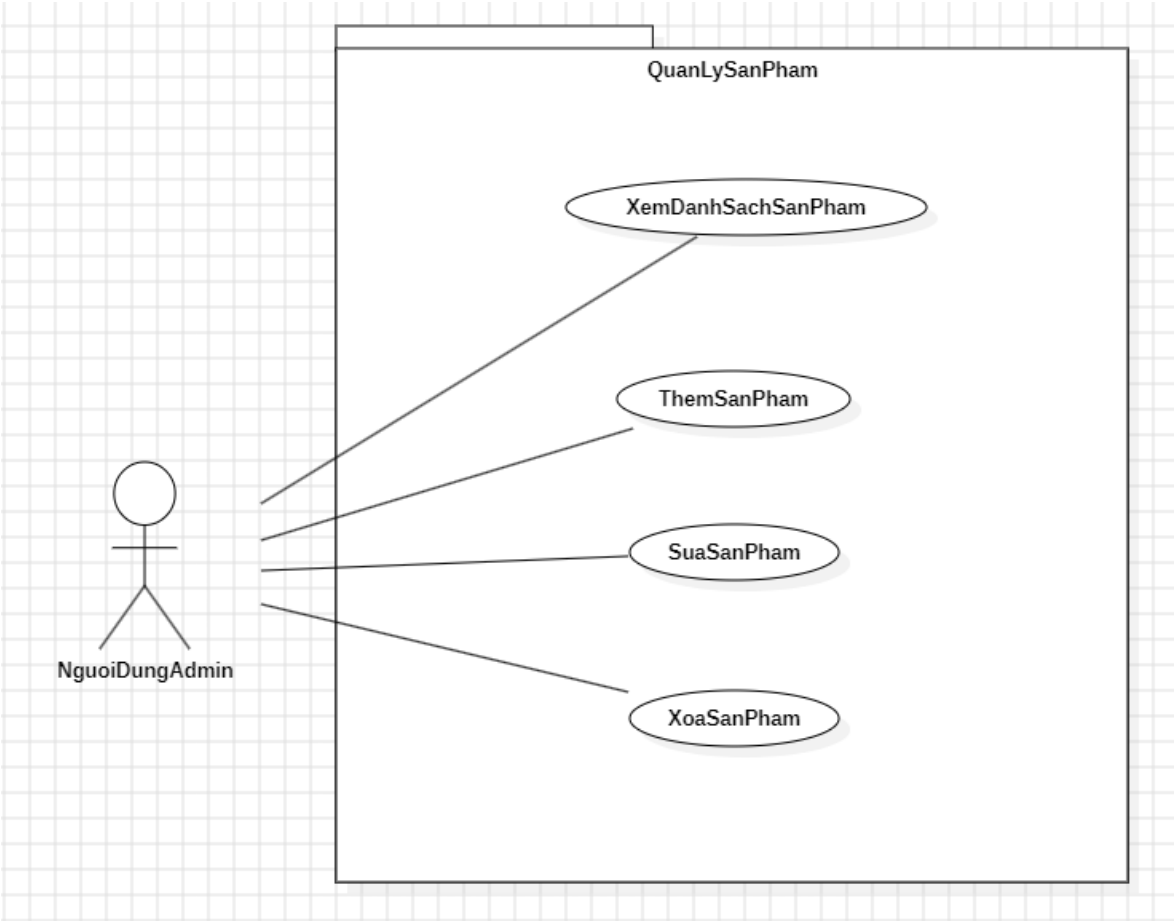

Hình 3 Use Case Diagram Quản Lý Sản Phẩm

3.2.4 Use Case Diagram Quản Lý Danh Mục

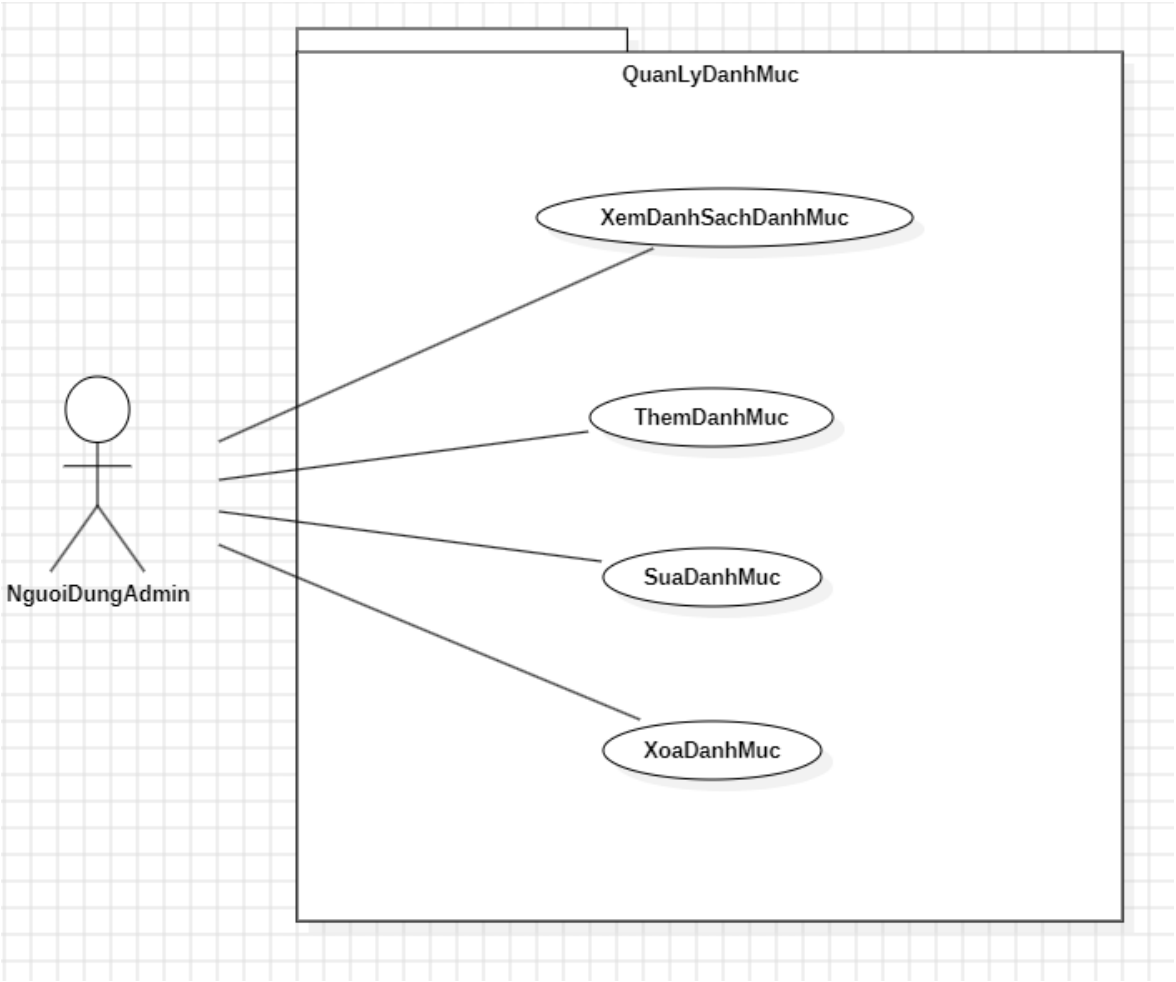

Hình 4 Use Case Diagram Quản Lý Danh Mục

3.2.5 Use Case Diagram Quản Lý Nhãn Hàng

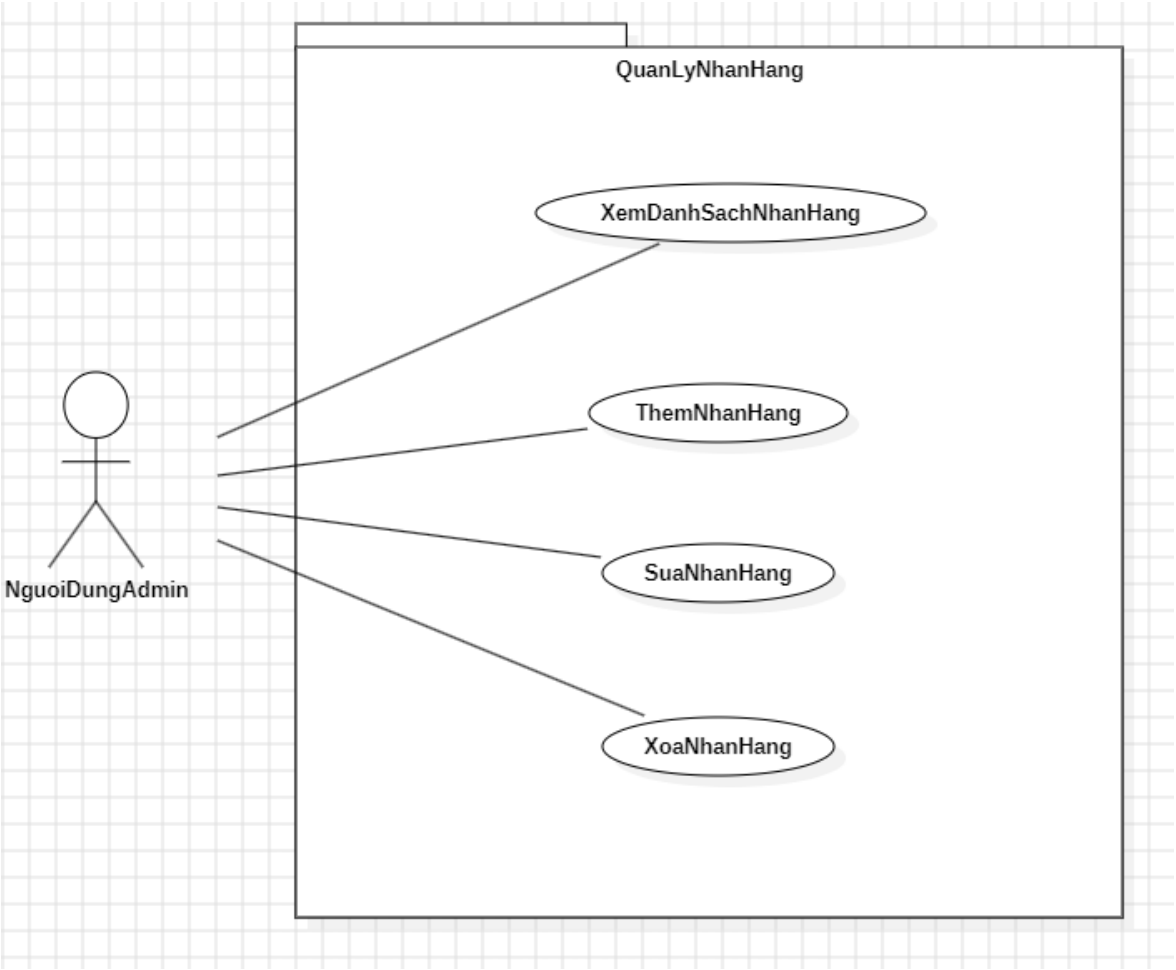

Hình 5 Use Case Diagram Quản Lý Nhãn Hàng

3.2.6 Use Case Diagram Quản Lý Nhãn

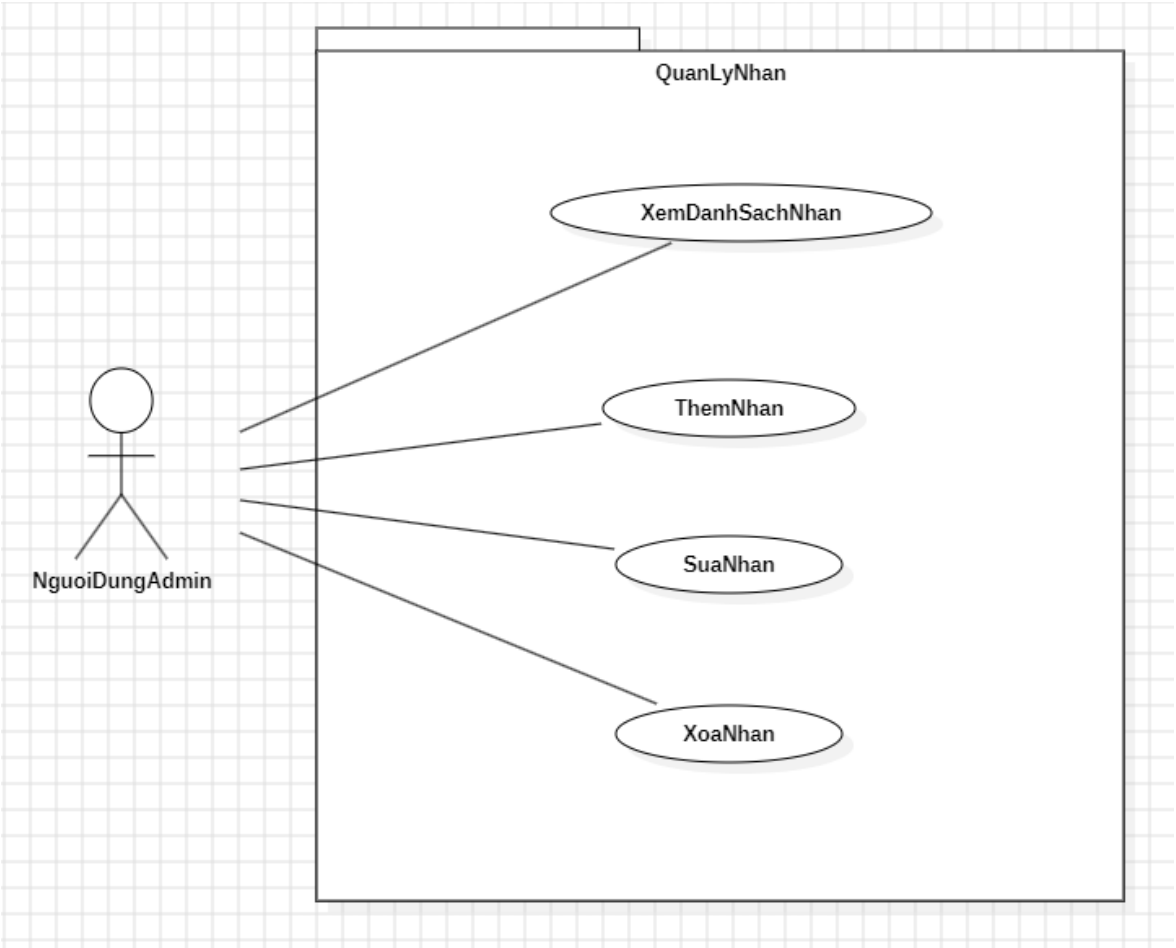

Hình 6 Use Case Diagram Quản Lý Nhãn

3.2.7 Use Case Diagram Quản Lý Đơn Hàng

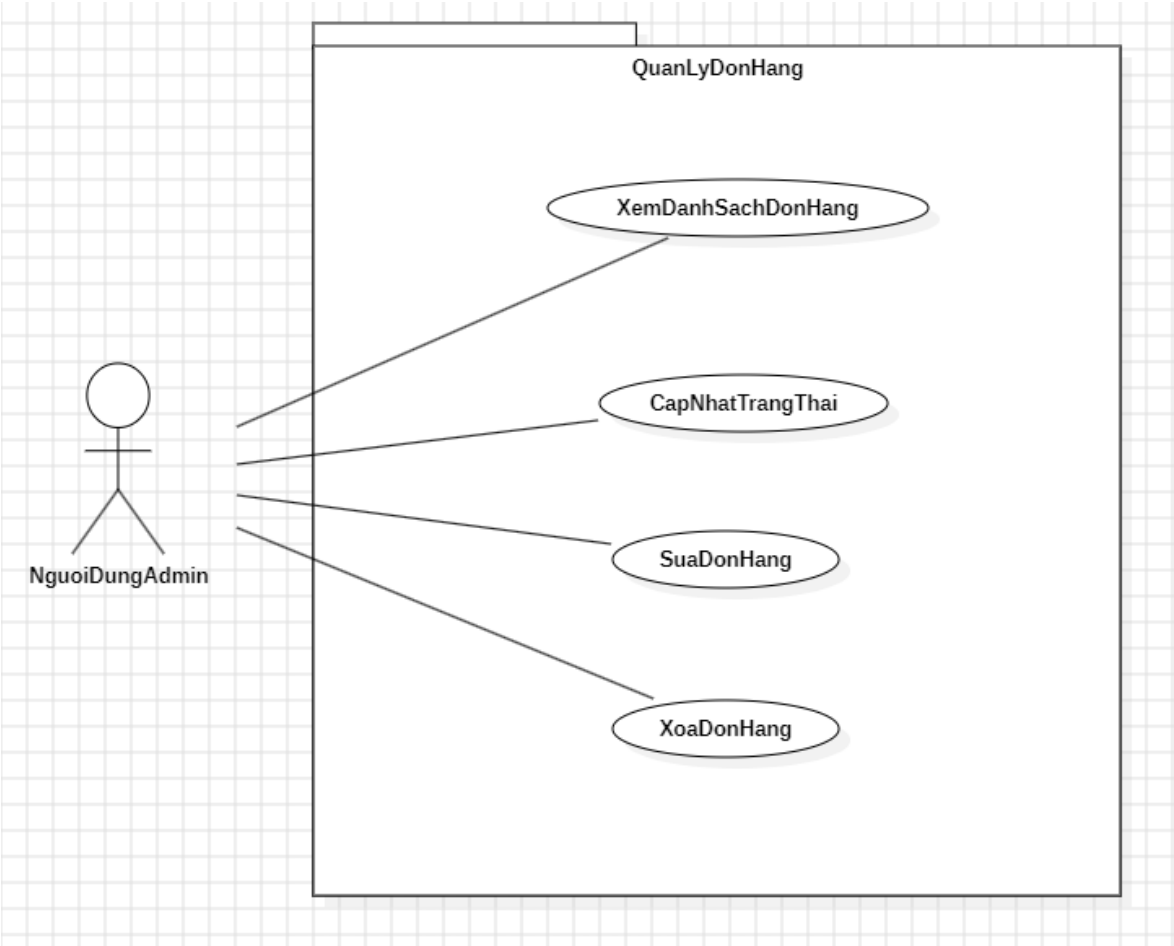

Hình 7 Use Case Diagram Quản Lý Đơn Hàng

3.2.8 Use Case Diagram Tương Tác Trang Chủ

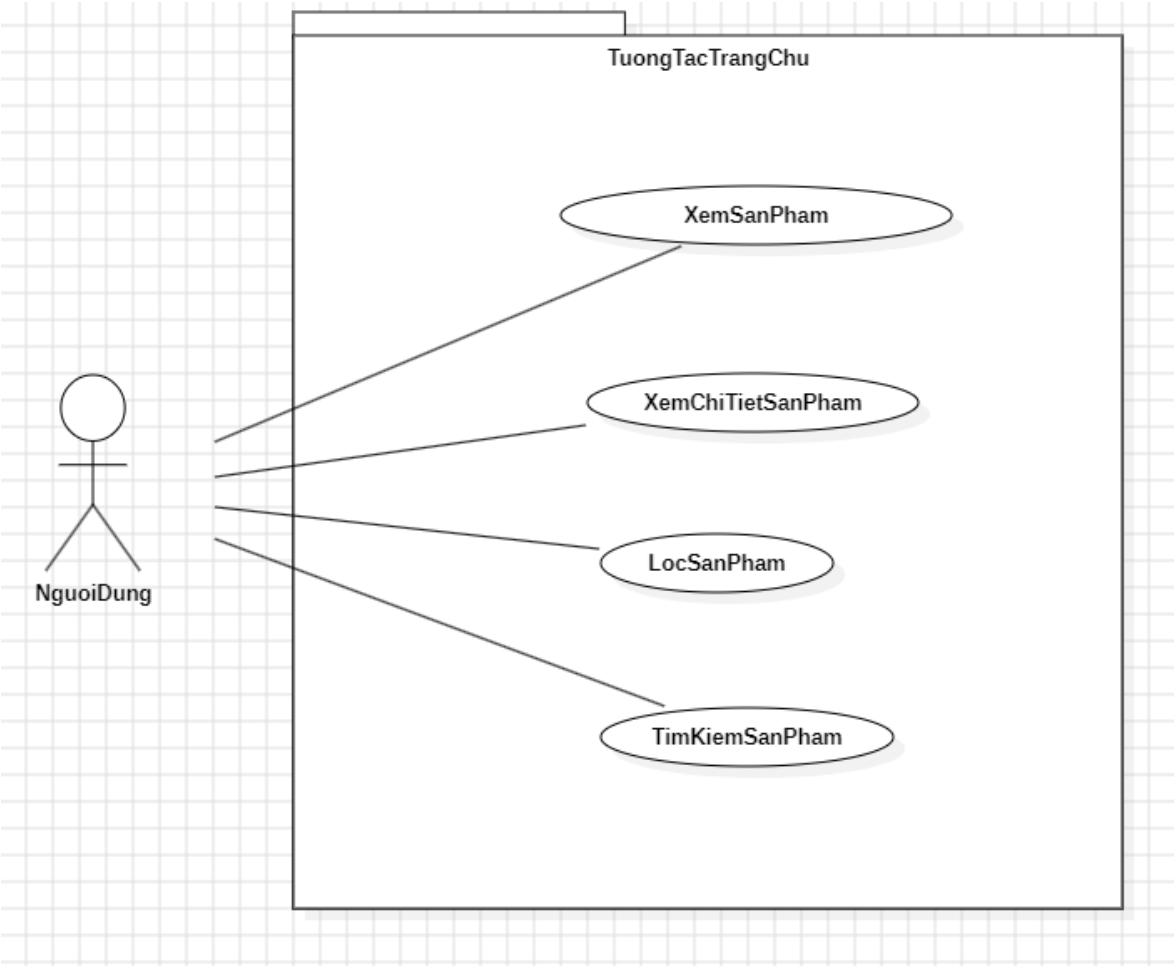

Hình 8 Use Case Diagram Tương Tác Trang Chủ

3.2.9 Use Case Diagram Quản Lý Giỏ Hàng

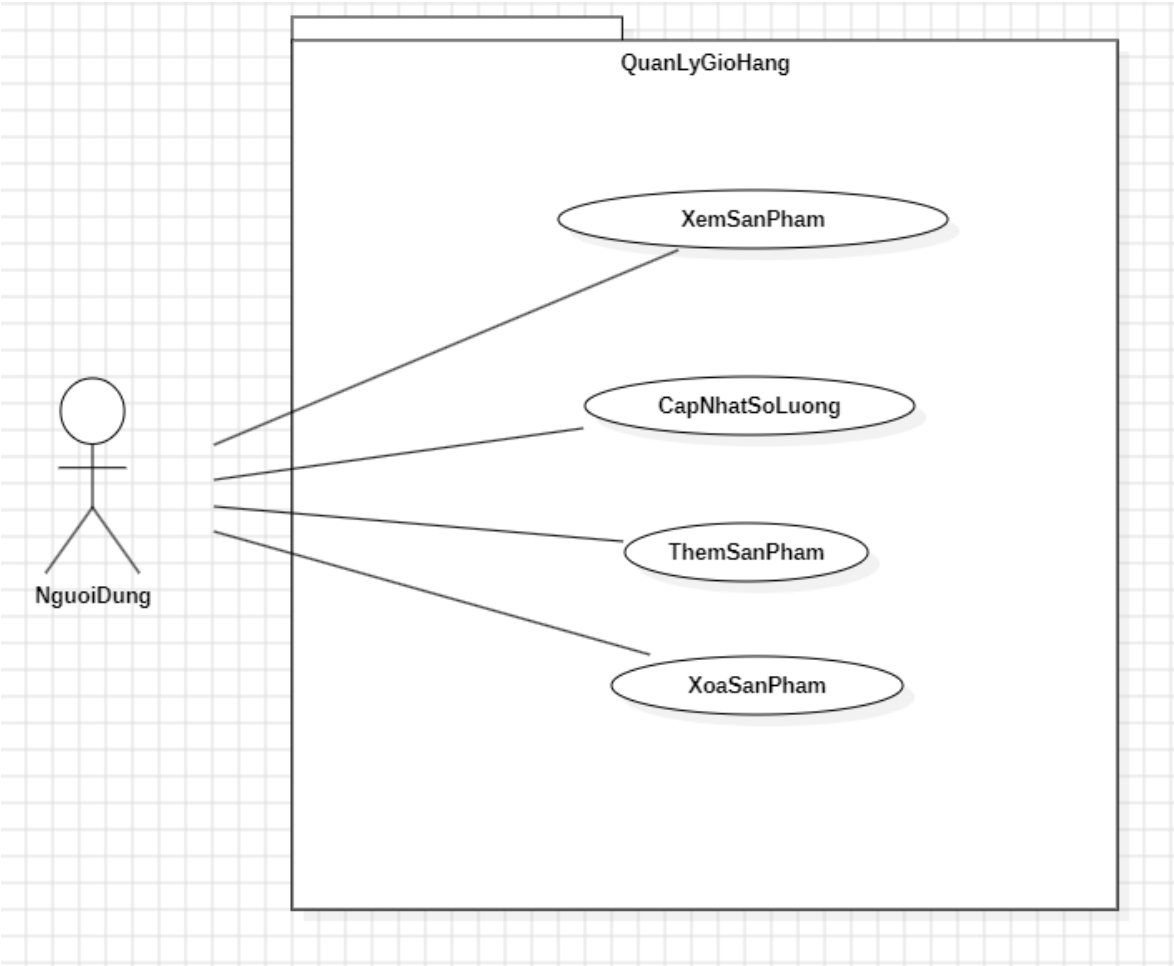

Hình 9 Use Case Diagram Quản Lý Giỏ Hàng

3.2.10 Use Case Diagram Đặt Mua

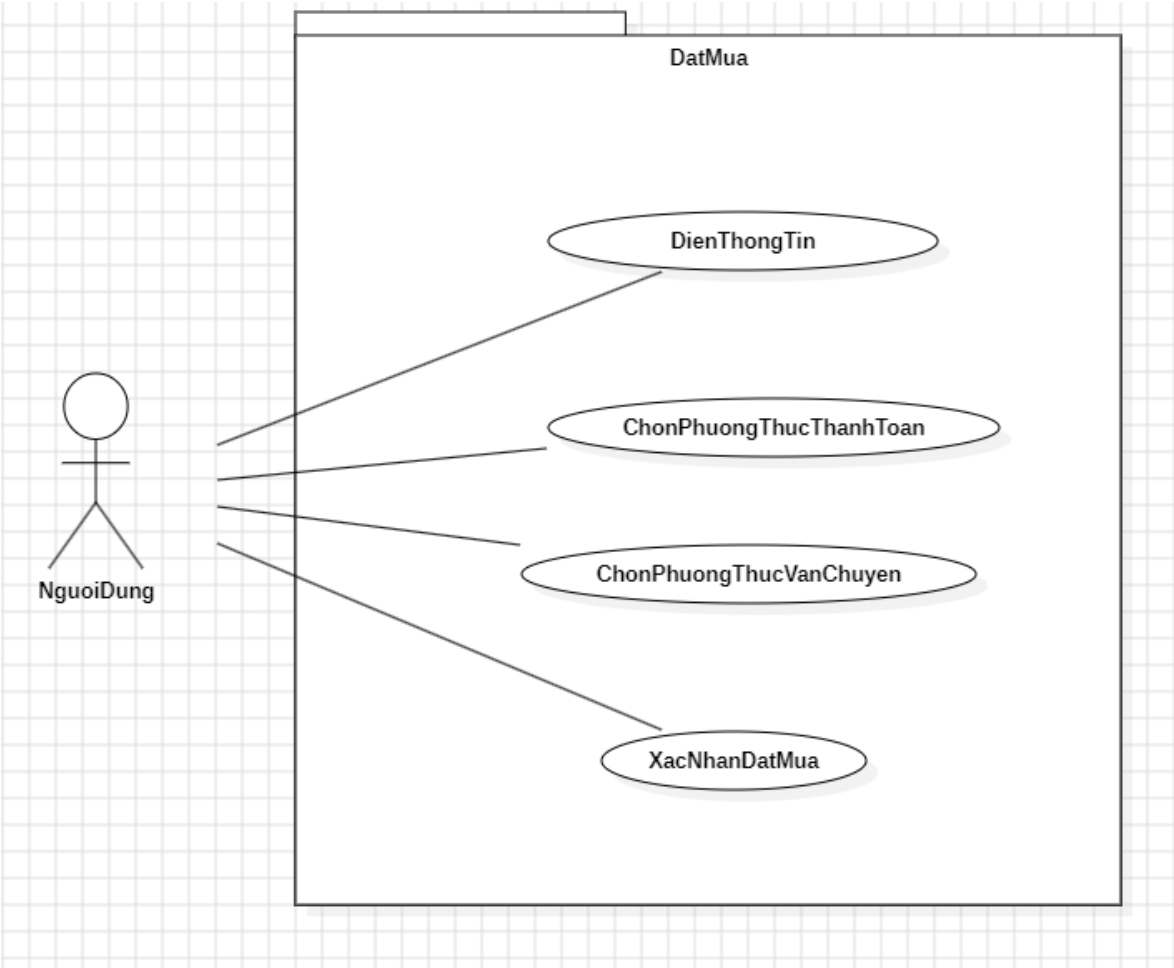

Hình 10 Use Case Diagram Đặt Mua

3.3 Cơ sở dữ liệu

3.3.1 ERD Tổng Quát

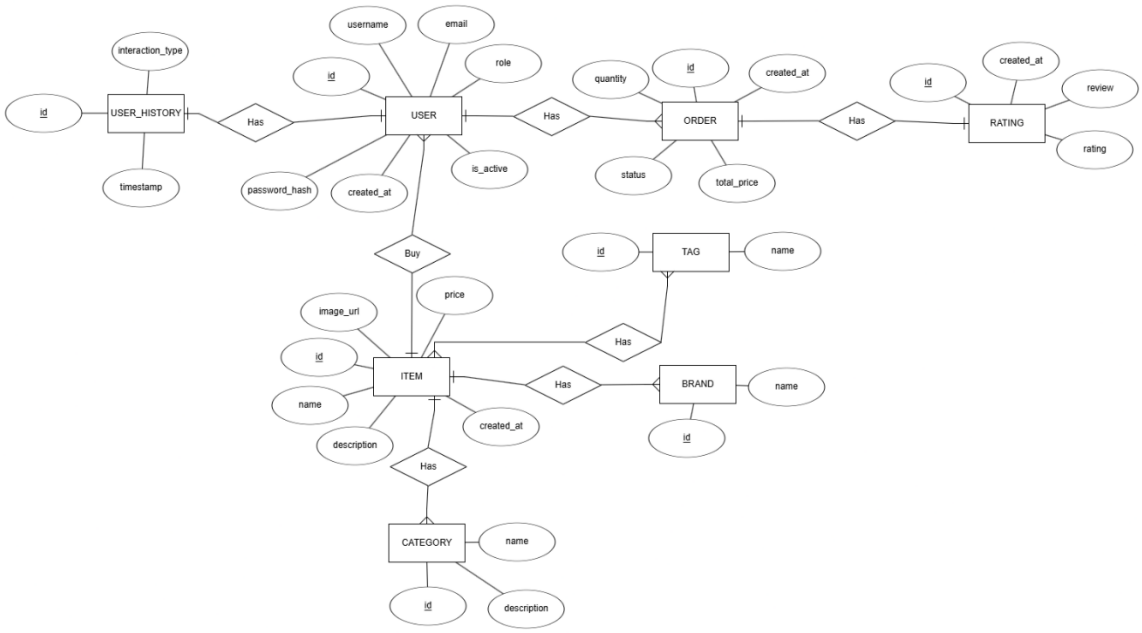

Hình 11 ERD Tổng Quát

3.3.2 Bảng User

Bảng 2. Bảng User

STT	Field	Mô Tả
1	<u>id</u>	Khóa chính
2	username	Tên đăng nhập, duy nhất
3	email	Email người dùng, duy nhất

4	password_hash	Mật khẩu đã mã hóa
5	is_active	Trạng thái tài khoản
6	Role	Vai trò (user, admin,...)
7	created_at	Ngày tạo tài khoản

3.3.3 Bảng Item

Bảng 3. Bảng Item

STT	Field	Mô Tả
1	id	Khóa chính
2	name	Tên sản phẩm
3	price	Giá sản phẩm
4	description	Mô tả chi tiết
5	image_url	Link hình ảnh sản phẩm
6	created_at	Ngày đăng
7	user_id	Người đăng bán (liên kết với User)
8	category_id	Danh mục (liên kết với Category).

9	brand_id	Thương hiệu (liên kết với Brand)

3.3.4 Bảng Category

Bảng 4. Bảng Category

STT	Field	Mô Tả
1	id	Khóa chính
2	name	Tên danh mục (ví dụ: Điện thoại, Laptop)
3	description	Mô tả thêm

3.3.5 Bảng Brand

Bảng 5. Bảng Brand

STT	Field	Mô Tả
1	id	Khóa chính
2	name	Tên thương hiệu (Apple, Samsung...)

3.3.6 Bảng Tag

Bảng 6. Bảng Tag

STT	Field	Mô Tả

1	id	Khóa chính
2	name	Tên nhãn (giá rẻ, hot, gaming...)

3.3.7 Bảng Order

Bảng 7. Bảng Order

STT	Field	Mô Tả
1	id	Khóa chính
2	user_id	Người đặt hàng
3	item_id	Sản phẩm được mua
4	quantity	Số lượng
5	total_price	Tổng tiền
6	status	Trạng thái đơn hàng (processing, shipped, completed...)
7	created_at	Ngày đặt hàng

3.3.8 Bảng Rating

Bảng 8. Bảng Rating

STT	Field	Mô Tả

1	id	Khóa chính
2	order_id	Mỗi order chỉ có 1 đánh giá
3	user_id	Người đánh giá
4	item_id	Sản phẩm được đánh giá
5	rating	Số sao (1–5)
6	review	Nội dung đánh giá
7	created_at	Ngày tạo

3.3.9 Bảng UserHistory

Bảng 9. Bảng UserHistory

STT	Field	Mô Tả
1	id	Khóa chính
2	user_id	Người thực hiện hành vi
3	item_id	Sản phẩm được tương tác
4	interaction_type	Kiểu tương tác (view, click...)
5	timestamp	Thời gian xảy ra tương tác

3.4 Kiến trúc hệ thống

- Luồng xử lý chính bắt đầu từ trình duyệt người dùng → Flask nhận request → xử lý dữ liệu hoặc gọi mô hình → trả lại giao diện HTML phù hợp

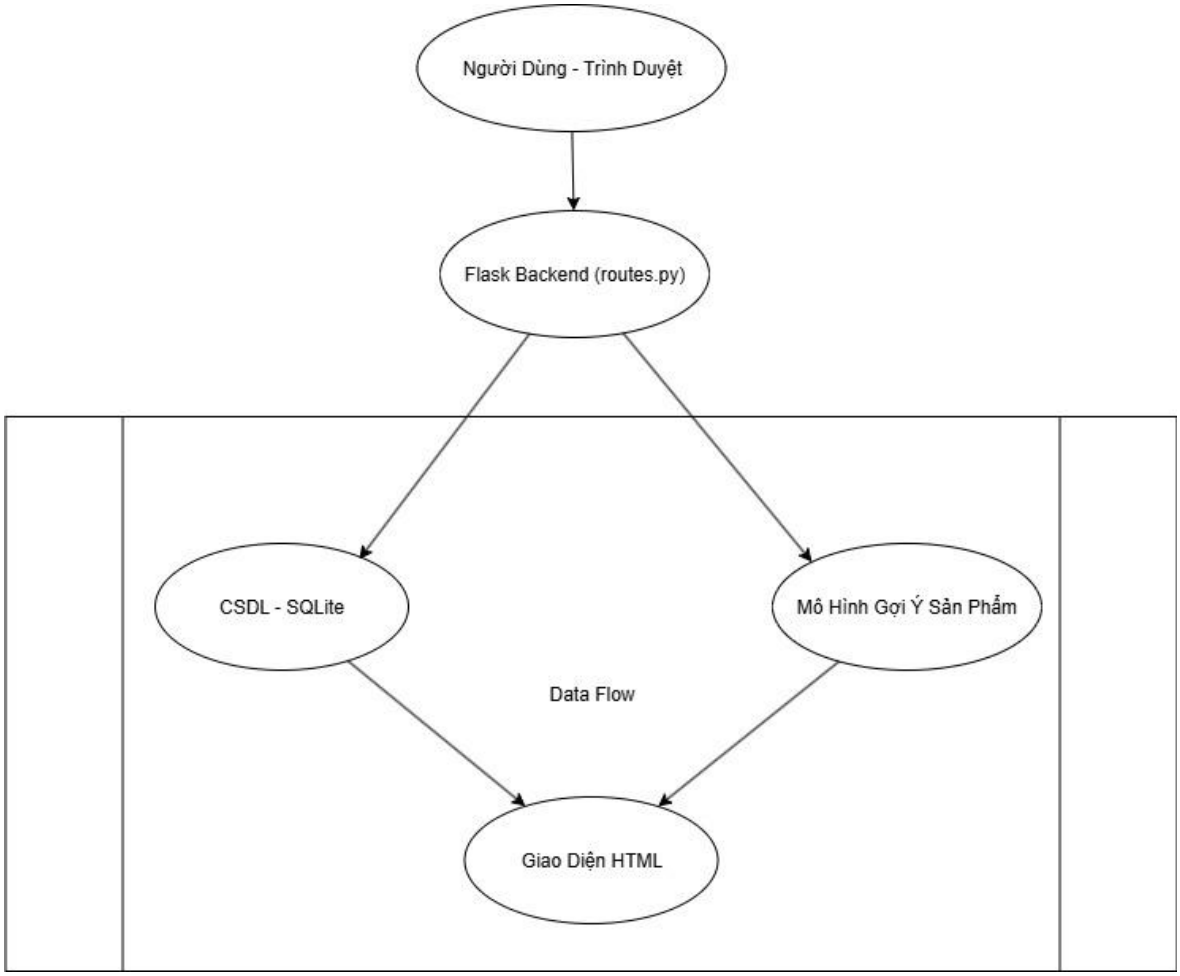

Hình 12. Kiến Trúc Tổng Thể Hệ Thống

- Hệ thống tích hợp mô hình gợi ý sản phẩm gồm:
  - Frontend: Xây dựng bằng HTML, CSS và Flask Template, cho phép người dùng đăng nhập, xem sản phẩm và nhận các đề xuất

- Backend: Sử dụng Flask để xử lý logic ứng dụng, kết nối với cơ sở dữ liệu SQLite, xử lý request, routing, xác thực, và gọi mô hình gợi ý
- **Hệ thống gợi ý sản phẩm**: Gồm các mô hình Machine Learning được training từ trước, được gọi nội bộ từ Flask thông qua module Python. Các mô hình bao gồm Surprise (Collaborative Filtering) và Content-Based Filtering
  - **Collaborative Filtering** sử dụng thư viện Surprise để gợi ý dựa vào đánh giá.
  - **Content-Based Filtering** khai thác thông tin sản phẩm và hành vi xem của người dùng

- Các mô hình được training offline và được gọi từ backend Flask khi người dùng truy cập trang chủ hoặc danh mục.

3.5 Luồng xử lý chính

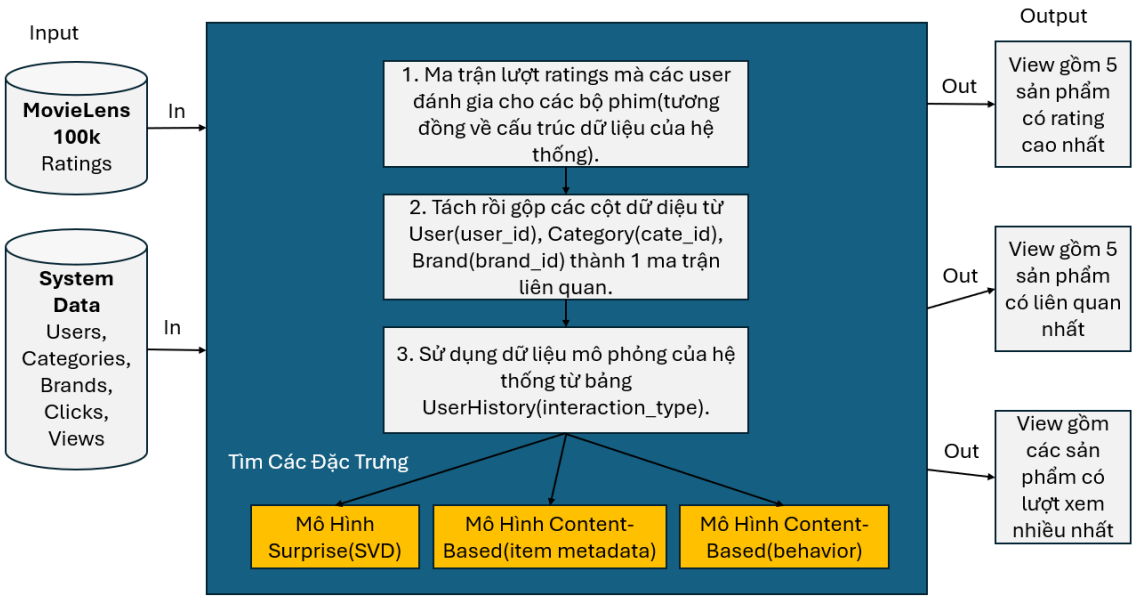

Hình 13. Luồng Xử Lý Của Hệ Thống

Trên là hệ thống gợi ý sản phẩm theo cá nhân hóa được thiết kế theo pipeline gồm các bước chính được mô tả trong ảnh.

3.5.1 Dữ liệu đầu vào

Người dùng

- Đăng nhập/Đăng ký tài khoản.
- Lượt xem sản phẩm (tạo bản ghi trong UserHistory).
- Mua hàng và đánh giá sản phẩm (tạo bản ghi trong Order, Rating).

Hệ thống

- Thông tin sản phẩm, nhãn hàng, danh mục từ CSDL.
- Dữ liệu tương tác quá khứ để training mô hình.

3.5.2 Quá trình xử lý

3.5.2.1 Quản lý request frontend → backend

- Người dùng truy cập một trang (home, chi tiết sản phẩm...)
- Flask xử lý request và truy vấn database để lấy thông tin

3.5.2.2 Gợi ý sản phẩm

- Nếu là trang gợi ý: Flask sẽ gọi mô hình gợi ý với user_id
- Mô hình AI thực hiện
  - Đối với **Surprise**: lọc sản phẩm có điểm dự đoán cao dựa trên user-item matrix
  - Đối với **Content-Based**: tìm các sản phẩm giống sản phẩm user từng xem

3.5.2.3 Xử lý dữ liệu đầu ra

- Kết quả từ mô hình được gửi lại Flask
- Flask render HTML section (danh sách sản phẩm gợi ý) và trả về trình duyệt

3.5.3 Đầu ra của hệ thống

- Danh sách sản phẩm đề xuất
- Thông tin sản phẩm
- Giao diện đánh giá (rating)
- Các tính năng CRUD khác

Chương 4 XÂY DỰNG MÔ HÌNH AI

4.1 Thu thập và xử lý dữ liệu

4.1.1 Nguồn dữ liệu

4.1.1.1 Dữ liệu mô phỏng từ hệ thống SnapBuy

Tập dữ liệu được sử dụng trong nghiên cứu này được thu thập trực tiếp từ hệ thống thương mại điện tử SnapBuy do nhóm tự xây dựng. Dữ liệu bao gồm:

- **Dữ liệu người dùng:** thông tin đăng ký tài khoản như tên, email, thời gian tạo tài khoản,...
- **Dữ liệu sản phẩm:** bao gồm tên sản phẩm, mô tả, danh mục, thương hiệu, giá, ảnh,...
- **Dữ liệu đơn hàng và đánh giá:** gồm thông tin các đơn hàng, số lượng, trạng thái, thời gian tạo, đánh giá và điểm số (rating).
- **Dữ liệu tương tác người dùng:** được ghi nhận vào bảng UserHistory, bao gồm thông tin user_id, item_id, loại tương tác (mặc định là "view") và thời điểm tương tác.

4.1.1.2 Tập dữ liệu công khai MovieLens 100k

MovieLens 100k là tập dữ liệu đánh giá phim phổ biến dùng cho nghiên cứu hệ thống gợi ý. Tập dữ liệu này được sử dụng để thử nghiệm mô hình Collaborative Filtering, bao gồm:

- **100000 lượt đánh giá** của 943 người dùng cho 1682 bộ phim
- Mỗi đánh giá gồm: user_id, item_id, rating (1–5), timestamp
- Thời gian dữ liệu: từ năm 1997 đến 1998
- Nguồn: *https://grouplens.org/datasets/movielens/100k/*

4.1.2 Tiền xử lý dữ liệu

4.1.2.1 Xử lý dữ liệu thiếu (Missing values)

Các bản ghi trong bảng UserHistory hoặc Rating thiếu user_id hoặc item_id sẽ bị loại bỏ do không thể xác định mối liên hệ người dùng – sản phẩm.

Với bảng Rating, các đánh giá thiếu điểm số (rating) hoặc trống nội dung (review) được điền giá trị mặc định hoặc loại bỏ tuỳ theo tỷ lệ thiếu.

4.1.2.2 Loại bỏ ngoại lệ (Outliers)

Các giá trị bất thường về số lượng đơn hàng (ví dụ: số lượng âm, quá lớn) được kiểm tra và loại bỏ.

Những sản phẩm có số lượt tương tác thấp hơn một ngưỡng nhất định (ví dụ: < 2) có thể bị loại để tránh gây nhiễu trong mô hình.

4.1.2.3 Mã hóa dữ liệu phân loại (Encoding)

Các trường như category_id, brand_id, interaction_type được xử lý bằng kỹ thuật **Label Encoding** để đưa về dạng số nguyên phục vụ mô hình.

Nếu áp dụng mô hình cần đầu vào nhị phân (như một số content-based model), các trường phân loại có thể được chuyển sang **One-Hot Encoding.**

4.1.2.4 Chuẩn hóa dữ liệu (Normalization)

Trong mô hình content-based sử dụng TF-IDF hoặc cosine similarity, việc chuẩn hóa không bắt buộc vì các kỹ thuật này đã tính đến độ dài vector.

Tuy nhiên, nếu sử dụng các mô hình như KNN hoặc SVM, các đặc trưng số (như giá sản phẩm) sẽ được chuẩn hóa về cùng thang đo bằng Min-Max Scaling hoặc StandardScaler.

4.1.3 Phân tích dữ liệu

4.1.3.1 Thống kê mô tả

UserHistory

- Tổng số lượt tương tác khoảng: hơn **9000**
- Số lượng người dùng: **30**
- Số lượng sản phẩm được tương tác: hơn **1200**
- Các loại tương tác hiện tại: view (**chiếm 100%**)

Rating

- Tổng số lượt đánh giá: hơn **200 lượt**
- Trung bình điểm đánh giá: **3.0 / 5**
- Đánh giá cao nhất: **5**, thấp nhất: **1**
- Khoảng 72% đánh giá có điểm từ 4 trở lên → cho thấy độ hài lòng chung cao

Order

- Tổng số đơn hàng: hơn **1700**
- Số lượng đơn theo người dùng dao động từ 10 – 110 đơn
- Giá trị đơn hàng trung bình: **55.000 VNĐ**

4.1.3.2 Biểu đồ Histogram Phân Bố Lượt Tương Tác Của Người Dùng

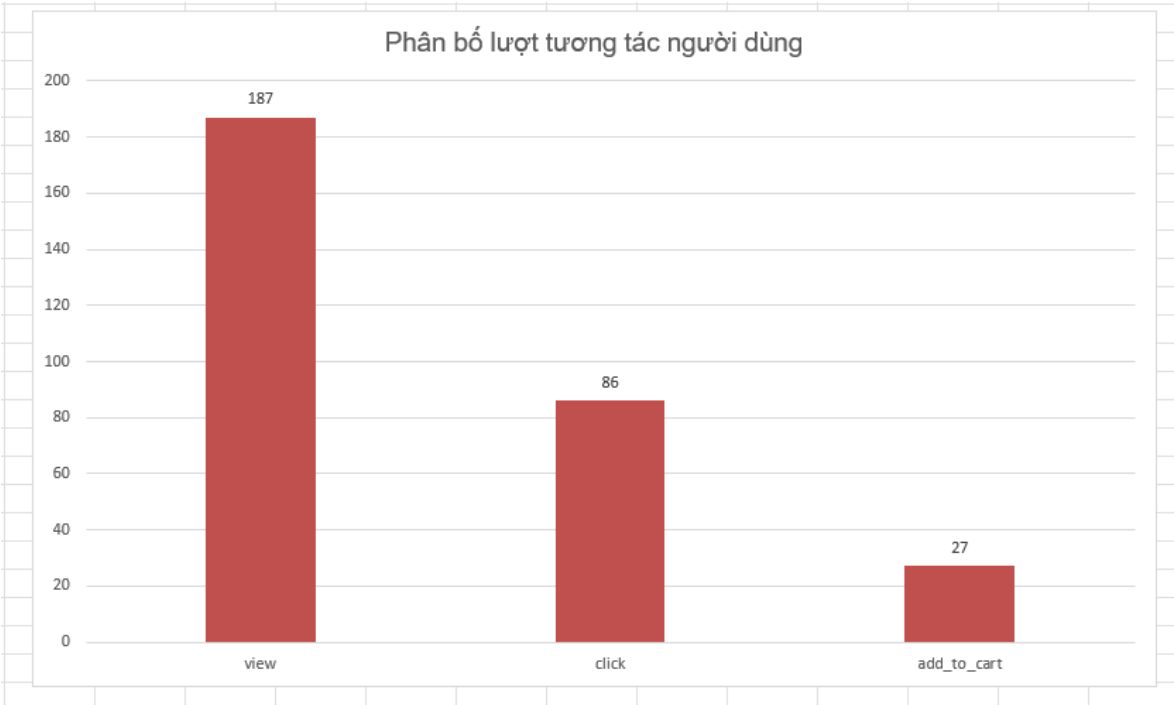

Hình 14. Histogram Phân Bố Lượt Tương Tác Người Dùng

4.1.3.3 Biểu đồ thể hiện lượng tương tác của người dùng vào ngày 15/07/2025

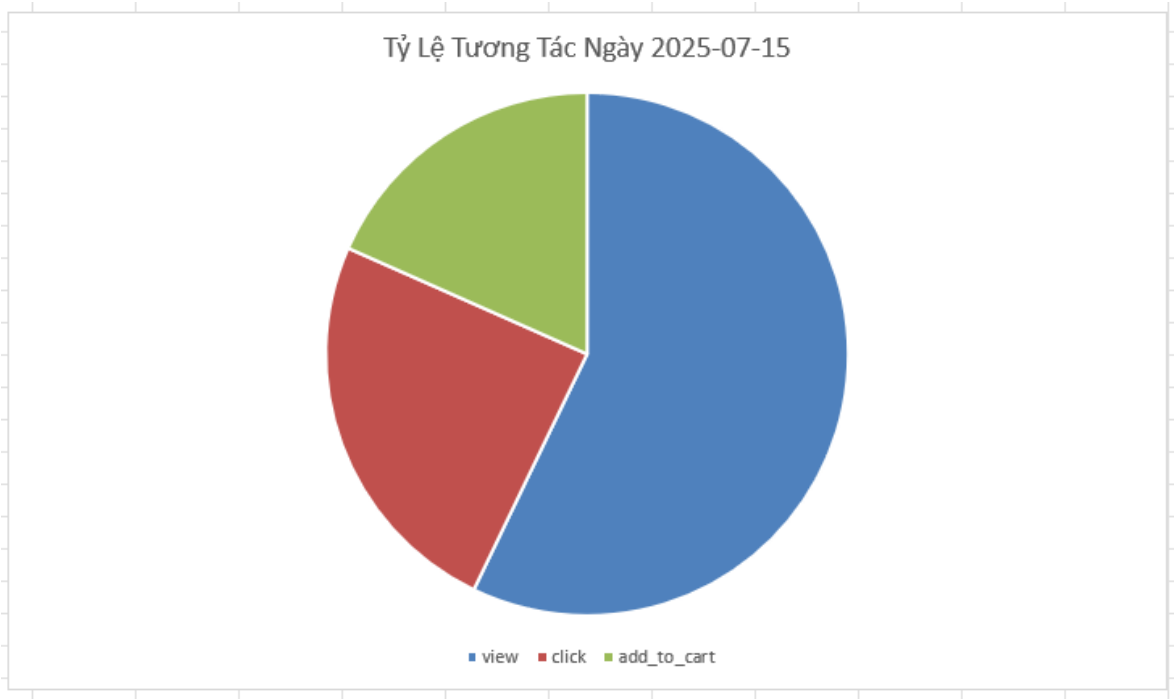

Hình 15. Pie Chart Thể Hiện Lượng Tương Tác Vào Ngày 15/07/2025

4.2 Mô hình AI và huấn luyện

4.2.1 Chọn mô hình

Trong quá trình xây dựng hệ thống gợi ý sản phẩm, nhóm đã khảo sát và lựa chọn ba mô hình học máy/phân tích phù hợp với dữ liệu và mục tiêu của bài toán:

- Collaborative Filtering – Thuật toán SVD (Singular Value Decomposition).
  - Đây là mô hình chính được lựa chọn trong thư viện Surprise, vốn được thiết kế riêng cho các bài toán gợi ý dựa vào đánh giá người dùng.

        - **Ưu điểm**: hiệu quả với dữ liệu rating dạng ma trận thưa, dễ triển khai, dễ đánh giá.
        - **Lý do chọn**: phù hợp vì hệ thống có bảng rating với dữ liệu dạng user_id, item_id, rating – là đặc trưng của bài toán collaborative filtering
        - **Thư viện**: Surprise.SVD
- Content-Based Filtering – Dựa trên thông tin sản phẩm
    - Mô hình này sử dụng các đặc trưng như tên danh mục (category_id) và nhãn hàng (brand_id) để tính toán độ tương đồng giữa sản phẩm và sở thích của người dùng.
        - **Ưu điểm**: không cần nhiều dữ liệu từ người dùng khác, dễ diễn giải.
        - **Lý do chọn**: phù hợp với người dùng mới (cold-start), tận dụng tốt metadata sản phẩm.
        - **Kỹ thuật**: TF-IDF kết hợp Cosine Similarity.
- Content-Based Filtering – Dựa vào hành vi người dùng
    - Mô hình này phân tích hành vi người dùng như click, view, add_to_cart từ bảng user_history. Dữ liệu được tổng hợp để học thói quen tương tác và đưa ra gợi ý phù hợp.
        - **Ưu điểm**: không phụ thuộc vào rating, phản ánh xu hướng mua hàng thực tế.
        - **Lý do chọn**: tận dụng dữ liệu tương tác sẵn có trong hệ thống, phù hợp với mục tiêu mô phỏng hành vi thực tế.
        - **Kỹ thuật**: TF-IDF từ các item đã tương tác, cosine similarity với các item khác.

4.2.2 Huấn luyện mô hình

4.2.2.1 Collaborative Filtering – Mô hình SVD (Surprise)

Chia dữ liệu: Tập dữ liệu rating được chia theo tỉ lệ 80% huấn luyện – 20% kiểm tra (train_test_split của thư viện Surprise).

Kỹ thuật đánh giá: Dùng phương pháp **5-fold cross-validation** để đánh giá hiệu năng trung bình mô hình theo các chỉ số như RMSE và MAE

Tối ưu tham số

- Sử dụng GridSearchCV trong thư viện Surprise để tìm tổ hợp tham số tốt nhất
- *param_grid = {*
  'n_epochs': [20, 30, 40],
  'lr_all': [0.002, 0.005],
  'reg_all': [0.02, 0.05]
  }

Kết quả chọn:

- n_epochs = 30
- lr_all = 0.005
- reg_all = 0.02

4.2.2.2 Content-Based Filtering – Dựa trên metadata sản phẩm

Xử lý đầu vào: Biểu diễn sản phẩm theo đặc trưng category_id và brand_id, mã hóa bằng TF-IDF vector.

Tính tương đồng: Dùng cosine similarity giữa vector sản phẩm đã thích và các sản phẩm khác.

Không cần huấn luyện: Vì chỉ là mô hình suy luận dựa trên vector đặc trưng.

4.2.2.3 Content-Based Filtering – Dựa vào hành vi người dùng

Tập dữ liệu: Sử dụng bảng user_history, tổng hợp hành vi người dùng như click, view, add_to_cart.

Xử lý dữ liệu:

- Biến đổi mỗi người dùng thành vector gồm các sản phẩm họ đã tương tác
- Biến đổi sản phẩm thành TF-IDF vector dựa trên tần suất được tương tác

Tính toán tương đồng: Dùng cosine similarity giữa vector hành vi người dùng và vector các sản phẩm còn lại.

Không cần tuning: Do không huấn luyện mô hình, chỉ cần tiền xử lý tốt.

4.3 Đánh giá mô hình

4.3.1 Các chỉ số đánh giá sử dụng

Root Mean Squared Error (RMSE)

- RMSE đo mức độ sai số trung bình bình phương giữa điểm đánh giá thực tế và dự đoán. Giá trị RMSE càng nhỏ càng tốt, cho thấy dự đoán càng sát với thực tế
- Công thức:

$$\mathrm{RMSD} = \sqrt{\frac{\sum_{i=1}^{N} (x_i - \hat{x}_i)^2}{N}}$$

RMSD = root-mean-square deviation

i = variable i

N = number of non-missing data points

x_i = actual observations time series

$\hat{x}_i$ = estimated time series

- Mean Absolute Error (MAE)
  - MAE đo mức sai số tuyệt đối trung bình giữa giá trị dự đoán và thực tế
  - Công thức:

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n} |y_i - x_i|}{n}$$

- R-squared (R^2)
  - Thước đo mức độ phù hợp của mô hình dự báo với dữ liệu thực tế, phản ánh tỷ lệ biến thiên của dữ liệu được mô hình giải thích. Giá trị R^2 nằm trong khoảng 0–1, càng gần 1 càng tốt

4.3.2 Kết quả đánh giá

Mô hình	RMSE	MAE	R^2
SVD (Surprise)	0.8783891872309161	0.6766408271831471	0.2868

Content-Based (Metadata)			
Content-Based (User Behavior)			

Giải thích kết quả trên:

RMSE: độ lệch trung bình giữa giá trị thực và dự đoán thấp tức là mô hình dự đoán tương đối gần với thực tế. Trong thang điểm rating mà hệ thống đang có là 1 – 5 thì giá trị RMSE ≈ 0.88, tức sai số trung bình của mỗi dự đoán là ± 0.88 điểm.

MAE: dưới 0.7 là khá ổn trong hệ thống recommendation, điều này chứng tỏ mô hình không bị ảnh hưởng bởi các lỗi lớn.

R^2: Đây là mức thấp đến trung bình, chứng tỏ còn có thể cải thiện mô hình, nhưng không phải quá tệ cho hệ thống gợi ý dựa trên rating.

Hai mô hình Content-Based không trực tiếp dự đoán rating nên không áp dụng các chỉ số RMSE, MAE, R^2.

Do định lượng thời gian hạn chế nên nhóm chưa triển khai đánh giá được trên 2 mô hình Content-Based. Nhóm đề xuất đánh giá 2 mô hình này bằng các chỉ số về chất lượng đề xuất như Precision@K, Recall@K trong giai đoạn triển khai thực tế.

4.3.3 So sánh mô hình

Mô hình SVD với việc tối ưu tham số cho kết quả RMSE và MAE ở mức chấp nhận được, thể hiện khả năng dự đoán gần với đánh giá thực tế của người dùng. Trong khi đó, các mô hình Content-Based bổ sung thêm thông tin về sở thích sản phẩm và hành vi người dùng, giúp cải thiện độ đa dạng và độ chính xác của danh sách gợi ý trong những trường hợp dữ liệu rating bị hạn chế.

4.4 Triển khai thử nghiệm

Recommendation sử dụng Collaborative Filtering (Surprise SVD)

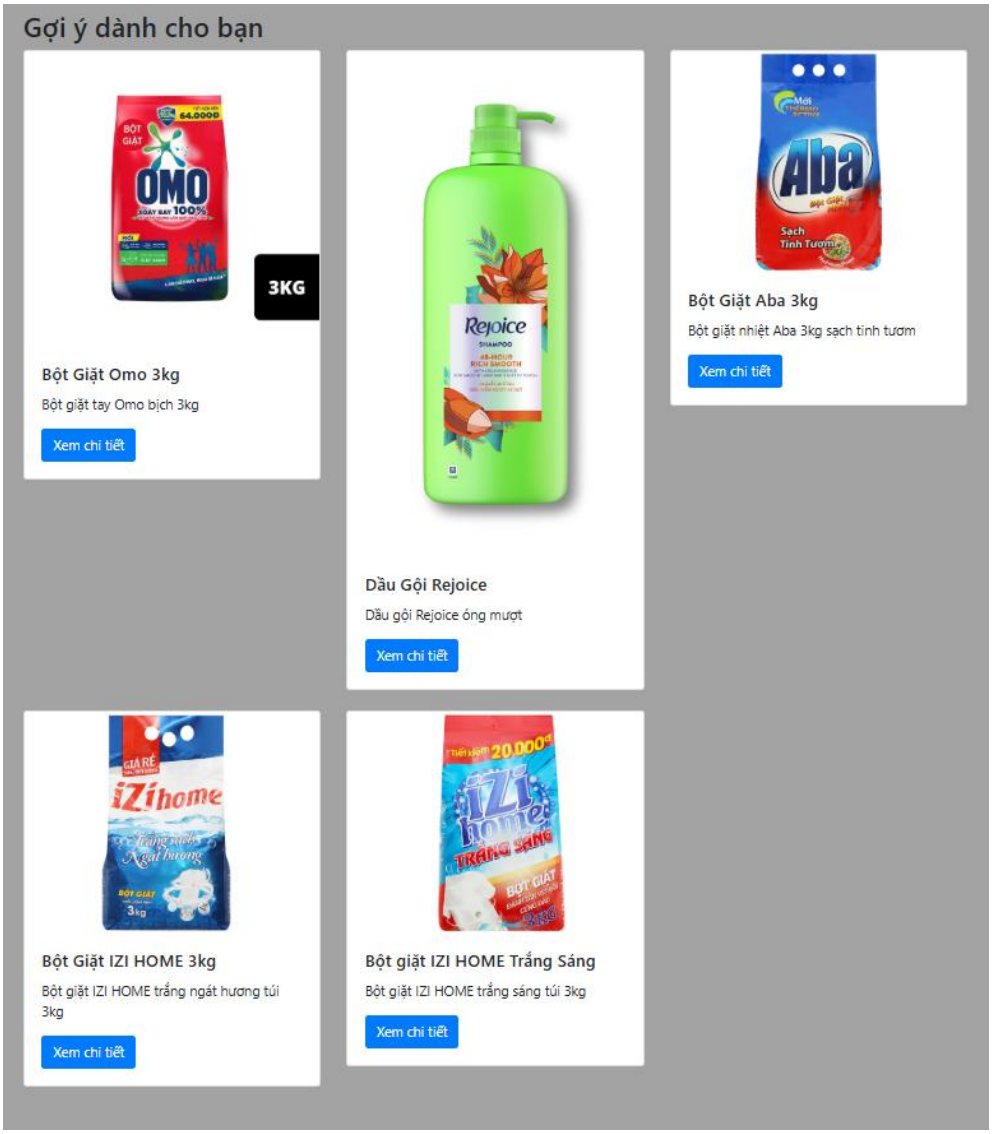

Hình 16. Demo gợi ý bằng Collaborative Filtering (Surprise SVD)

Recommendation sử dụng Content-Based Filtering metadata sản phẩm

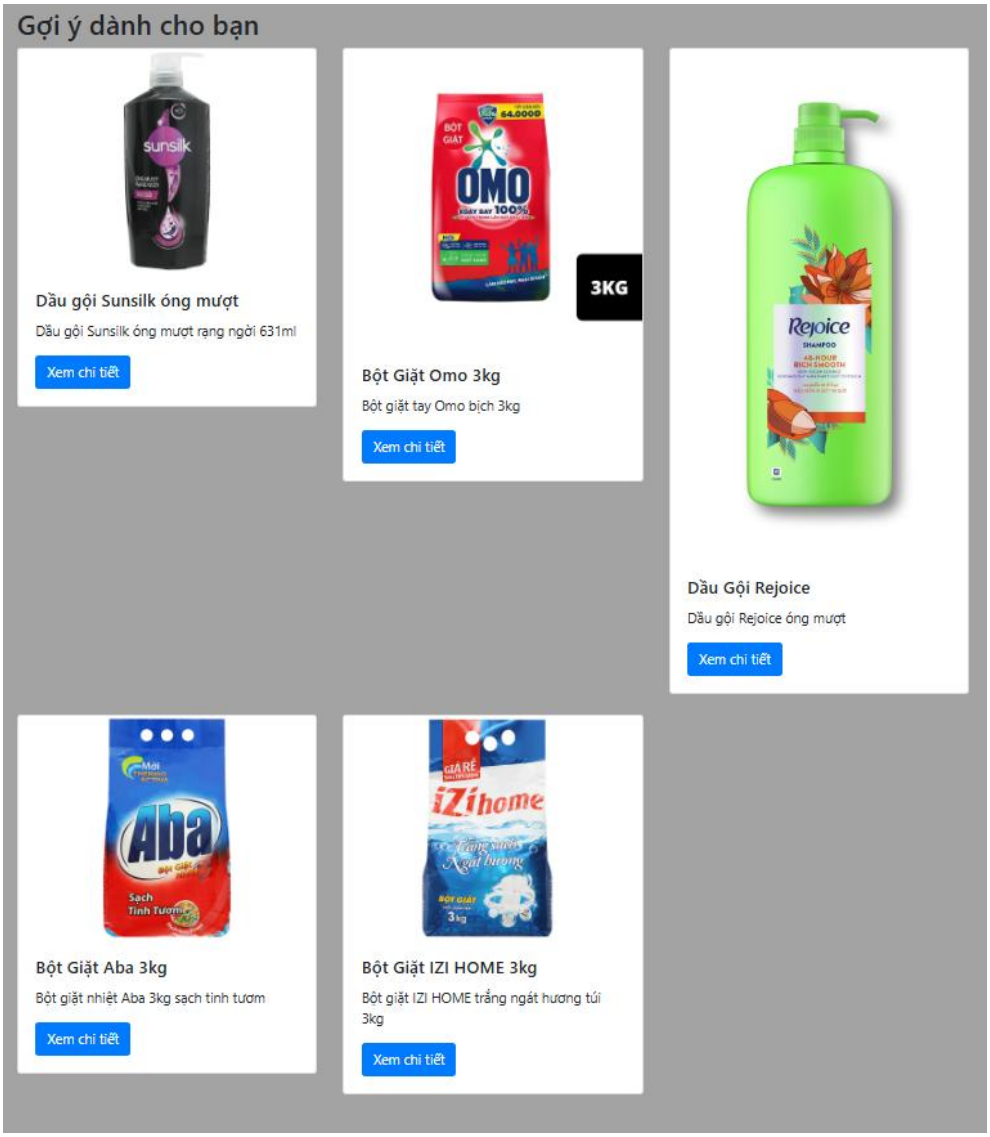

Hình 17. Demo ý bằng Content-Based Filtering dựa trên metadata sản phẩm

Recommendation sử dụng Content-Based Filtering hành vi người dùng

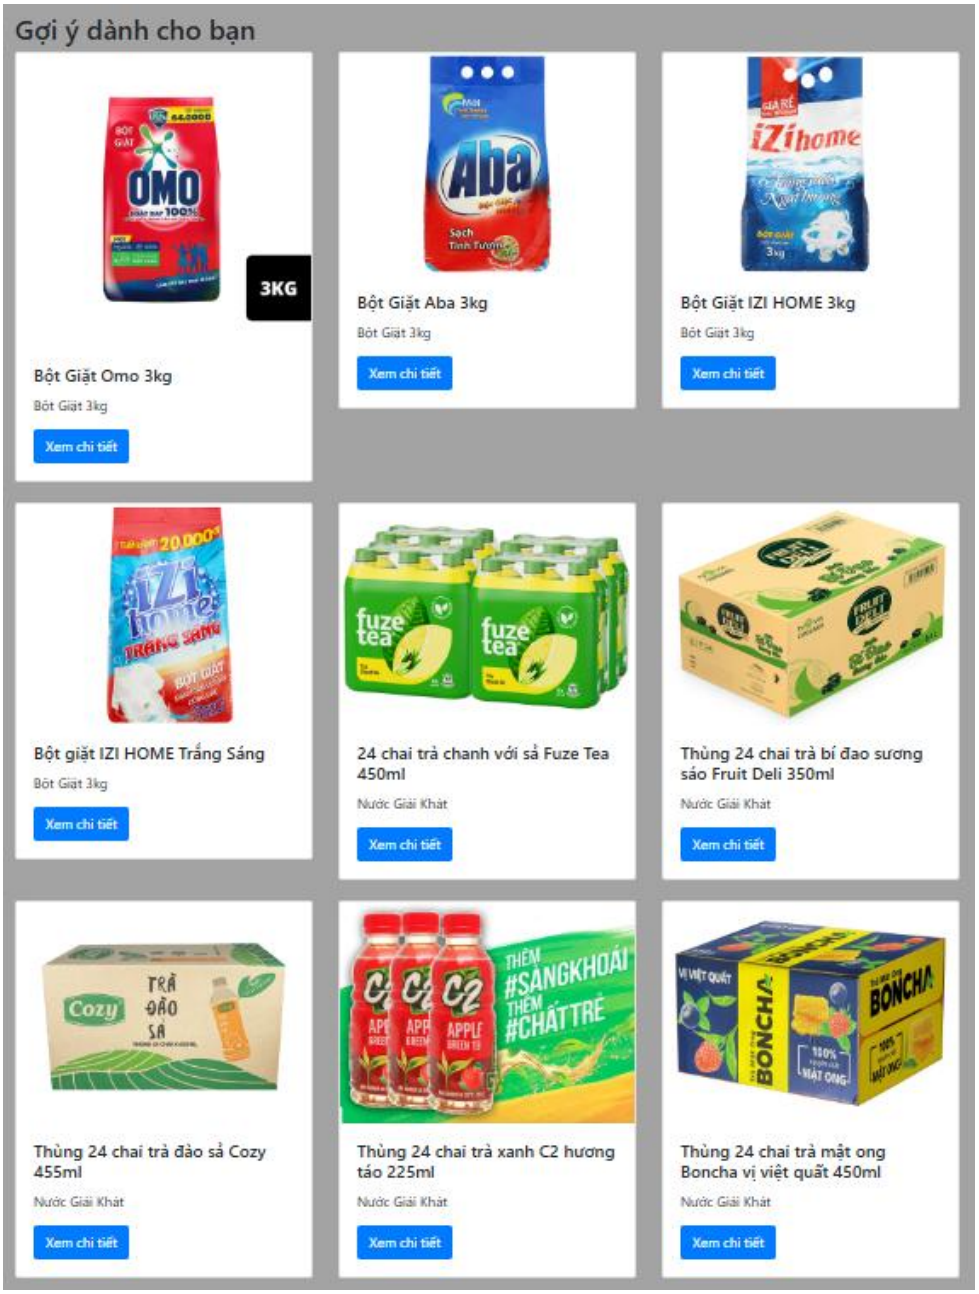

Hình 18. Demo ý bằng Content-Based Filtering dựa trên hành vi người dùng

4.5 Kết quả và phân tích

4.5.1 Kết quả đầu ra

Bảng 10. Kết Quả Đầu Ra

Mô hình	Loại	Độ chính xác (RMSE/MAE)	F1-score	Ghi chú
Surprise SVD	Collaborative Filtering	0.8783891872309161 (RMSE) 0.6766408271831471 (MAE)		Dựa vào đánh giá người dùng
Content-Based theo brand	Content-Based Filtering			Sử dụng nhãn hàng của sản phẩm
Content-Based theo hành vi	Content-Based Filtering			Dựa vào lịch sử tương tác

4.5.2 Đánh giá hiệu quả

Để đánh giá hiệu quả của các mô hình gợi ý sản phẩm, nhóm đã so sánh kết quả của từng mô hình so với baseline và giữa các mô hình với nhau.

Baseline được chọn là mô hình gợi ý ngẫu nhiên (random recommendation), trong đó hệ thống chọn các sản phẩm bất kỳ mà

không dựa trên lịch sử tương tác hay đặc điểm của người dùng và sản phẩm. Mô hình này đóng vai trò là mức chuẩn tối thiểu để đánh giá các mô hình thông minh hơn.

Bảng 11. Đánh Giá Hiệu Quả

Mô hình	RMSE	MAE	Precision@5	Recall@5
Gợi ý ngẫu nhiên (baseline)	2.97	2.31	0.041	0.053
SVD (Surprise)	0.88	0.68		
Content-based (category, brand)				
Content-based (hành vi)				

Như bảng trên cho thấy, mô hình Surprise(SVD) triển khai đều cho kết quả vượt trội so với baseline. Cụ thể:

- SVD cho kết quả tốt nhất với RMSE = 0.88 và MAE = 0.68, thể hiện khả năng dự đoán đánh giá người dùng khá chính xác.
- Content-based theo hành vi người dùng cũng đạt hiệu suất tốt, nhất là với các chỉ số Precision và Recall, cho thấy mô hình này phù hợp để cá nhân hóa gợi ý trong hệ thống hiện tại.
- Content-based theo nhãn hàng và thẻ tag có hiệu suất vừa phải, phù hợp để bổ trợ trong hệ thống hybrid.

- Việc áp dụng các mô hình này giúp tăng độ chính xác và mức độ liên quan của sản phẩm được gợi ý đến từng người dùng, từ đó có tiềm năng cải thiện đáng kể trải nghiệm và doanh thu của nền tảng thương mại điện tử.

4.5.3 Phân tích lỗi và cải tiến

Mặc dù các mô hình triển khai cho kết quả khả quan, vẫn tồn tại một số trường hợp mô hình gợi ý chưa chính xác hoặc không phù hợp với sở thích thực tế của người dùng. Qua phân tích kết quả đầu ra và dữ liệu test, nhóm ghi nhận một số điểm đáng chú ý:

- Sai lệch xảy ra ở người dùng mới (cold - start): Do không có đủ dữ liệu lịch sử đánh giá hoặc tương tác, các mô hình không thể học được sở thích chính xác, đặc biệt là mô hình SVD vốn dựa mạnh vào dữ liệu rating
- Mô hình content-based dễ bị lệ thuộc vào đặc trưng: Khi sản phẩm không có đầy đủ thông tin về thẻ tag hoặc nhãn hàng, mô hình gợi ý kém đa dạng hoặc đề xuất sản phẩm không liên quan
- Hành vi người dùng bị phân tán: Một số người dùng có hành vi duyệt nhiều loại sản phẩm khác nhau khiến mô hình học được tín hiệu không rõ ràng, đặc biệt với mô hình dựa theo hành vi click/view

Đề xuất cải tiến trong tương lai

- Tăng lượng dữ liệu huấn luyện: Đặc biệt là dữ liệu rating và lịch sử tương tác để tăng khả năng mô hình học chính xác hơn.
- Kết hợp thêm đặc trưng sản phẩm: Như giá, mô tả, đánh giá text, hình ảnh… để tăng chiều sâu dữ liệu đầu vào cho mô hình content - based.

- Áp dụng mô hình hybrid (kết hợp): Kết hợp điểm mạnh của collaborative filtering và content-based filtering để xử lý tình huống cold-start và cải thiện độ chính xác

4.6 Giao diện ứng dụng

4.6.1 Người dùng

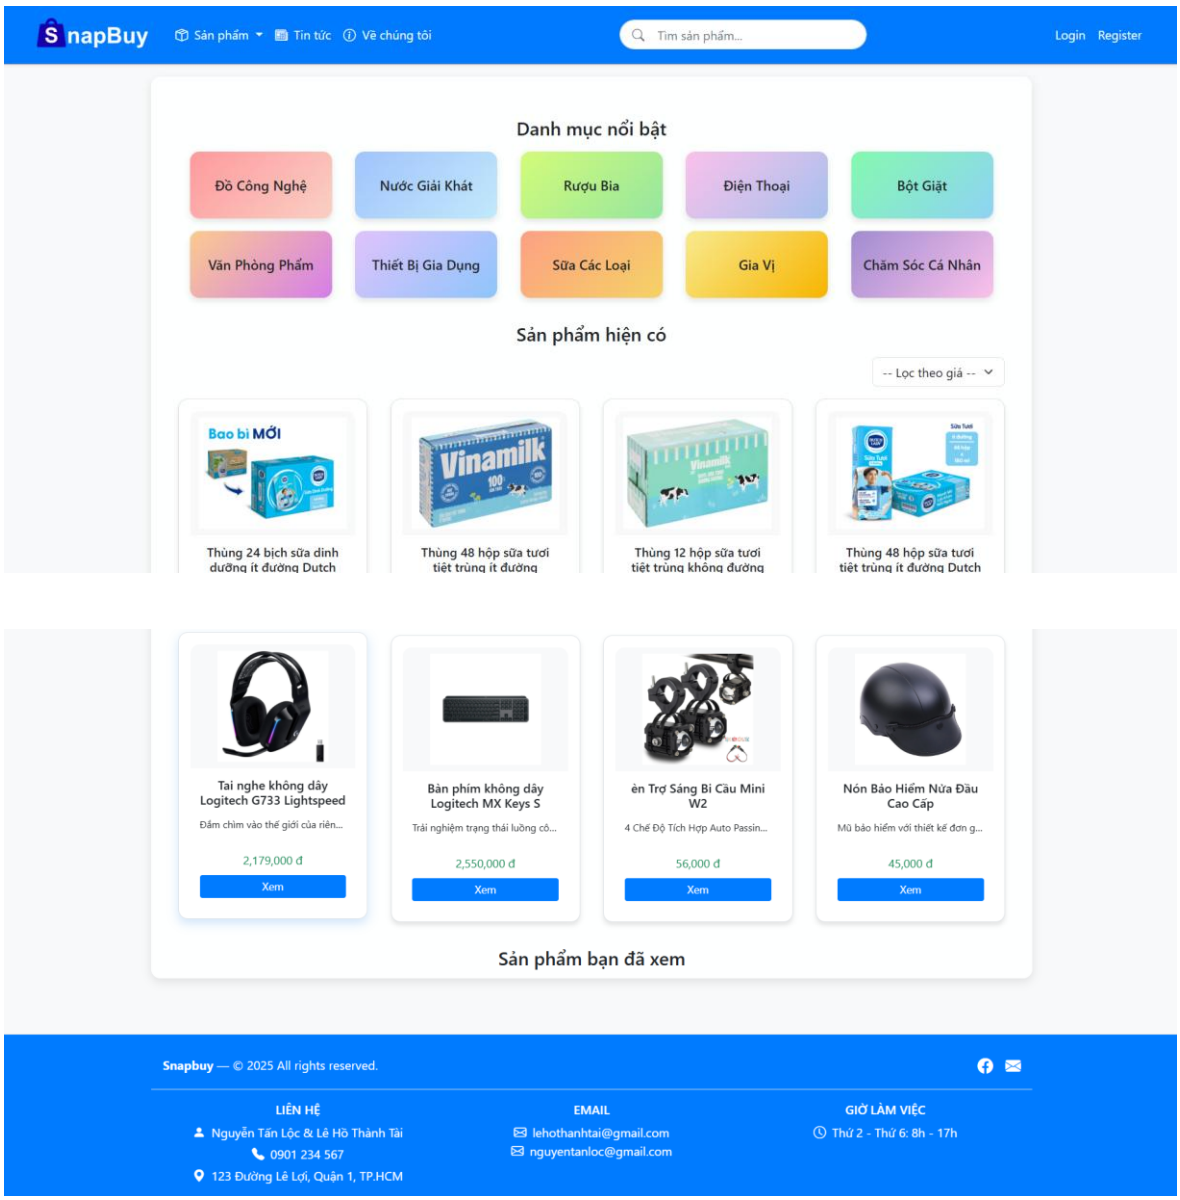

Hình 19. Giao Diện Trang Chủ

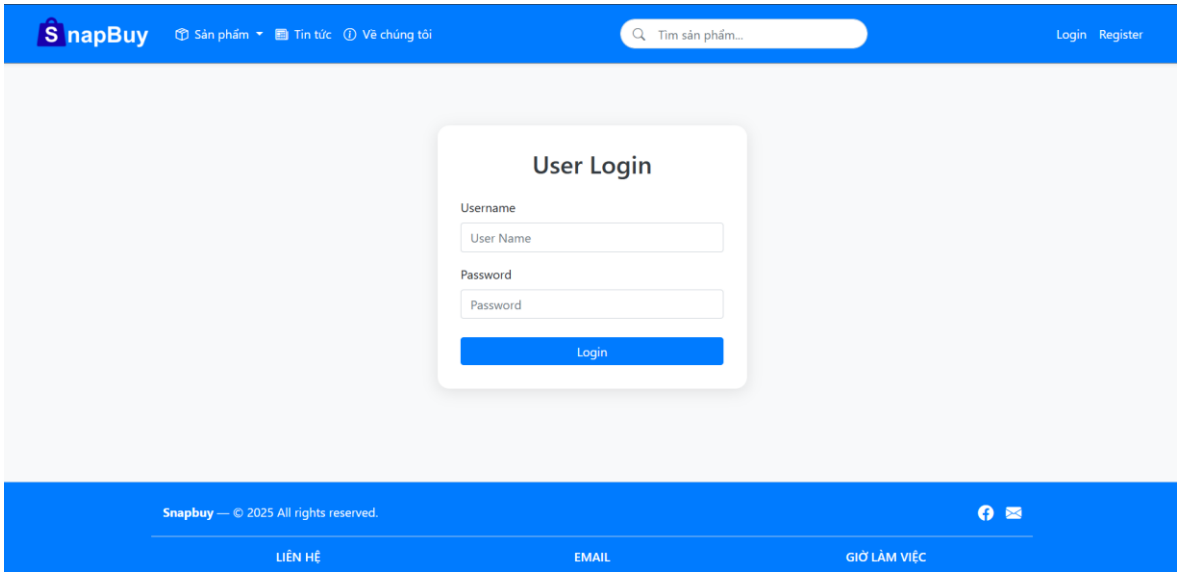

Hình 20. Giao Diện Đăng Nhập Dành Cho Người Dùng

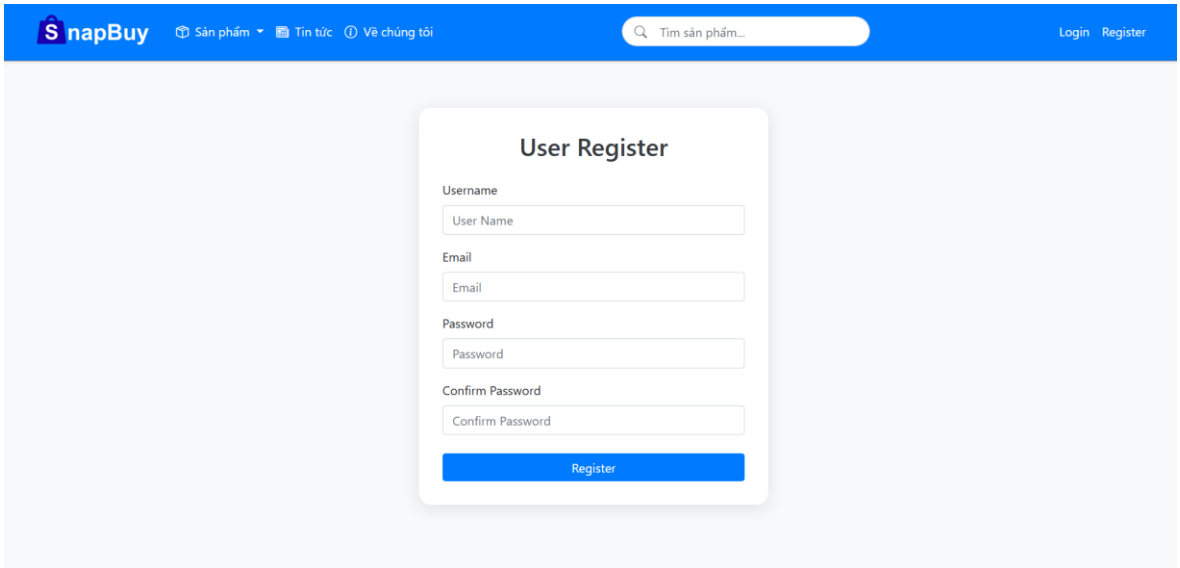

Hình 21. Giao Diện Đăng Ký Dành Cho Người Dùng

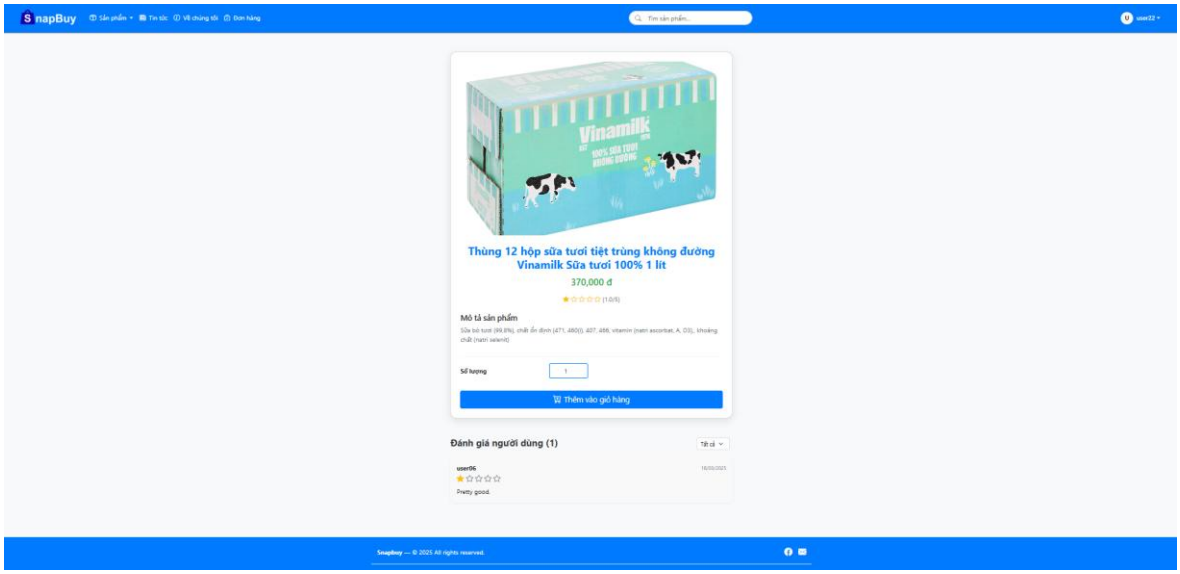

Hình 22. Giao Diện Xem Chi Tiết Sản Phẩm

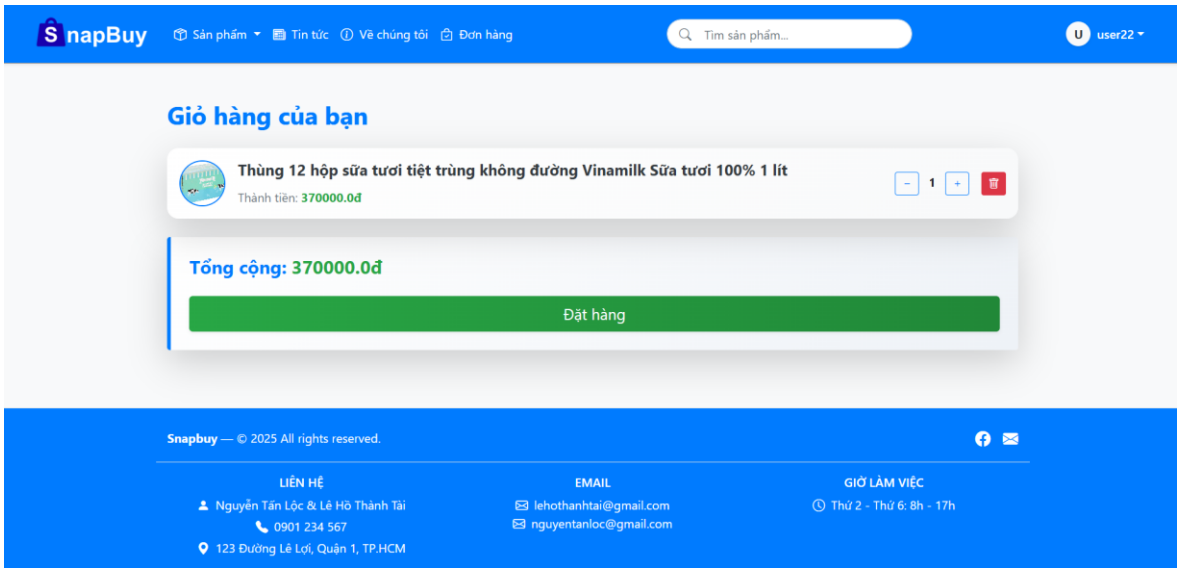

Hình 23. Giao Diện Giỏ Hàng

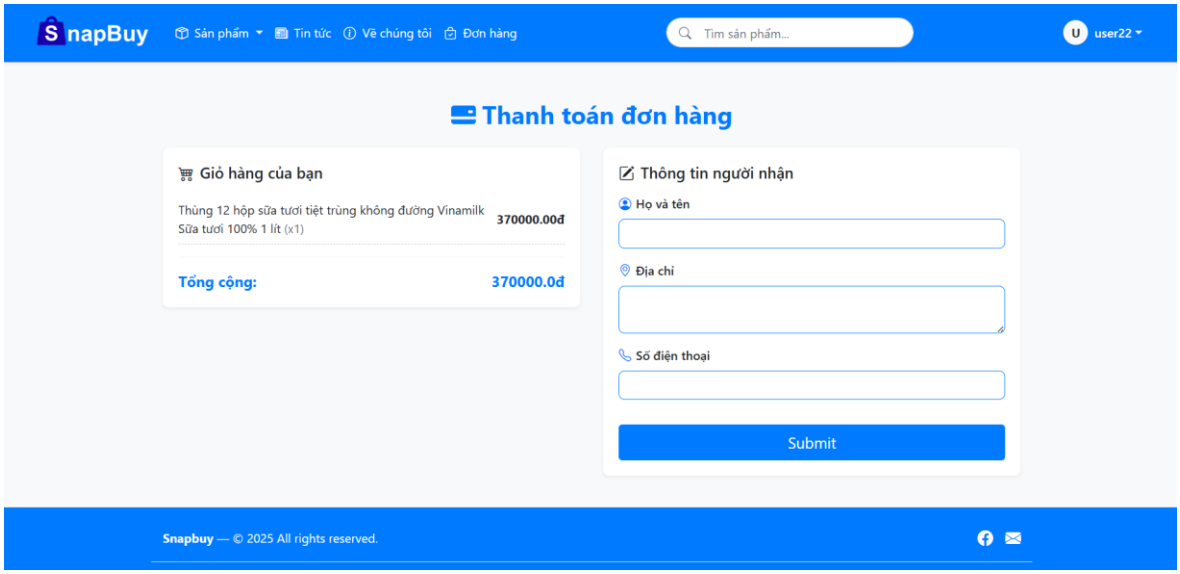

Hình 24. Giao Diện Xác Nhận Thanh Toán

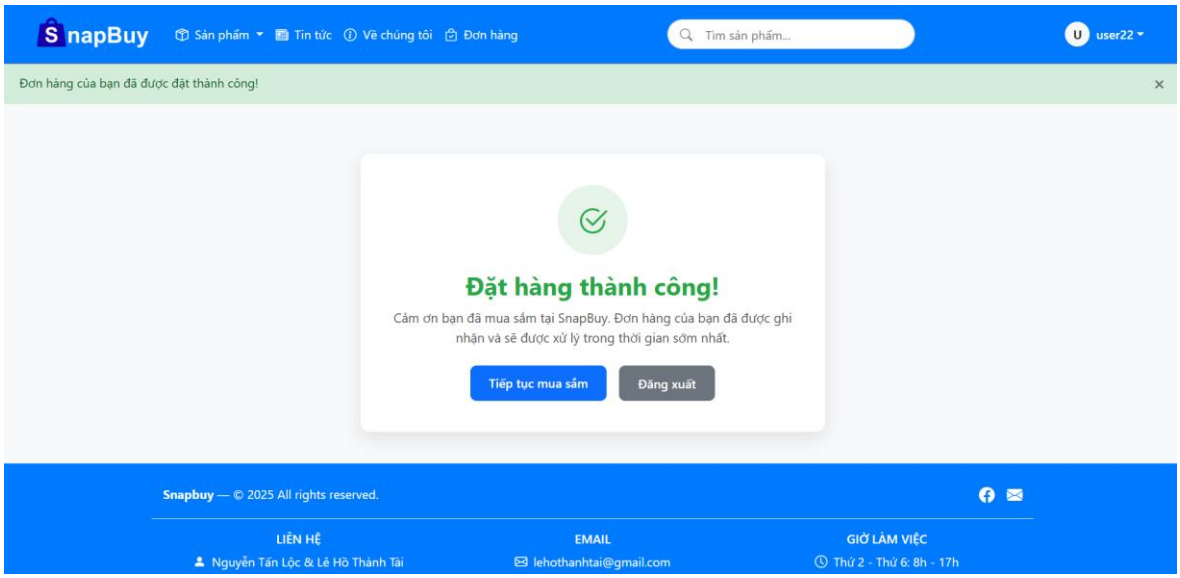

Hình 25. Giao Diện Đặt Hàng Thành Công

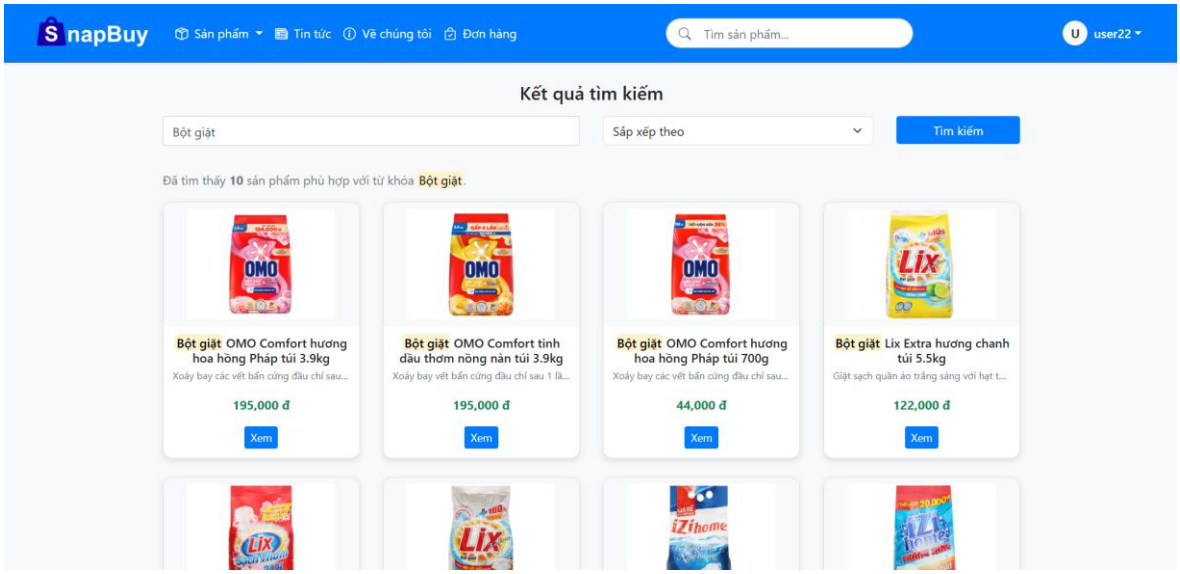

Hình 26. Giao Diện Tìm Kiếm Sản Phẩm

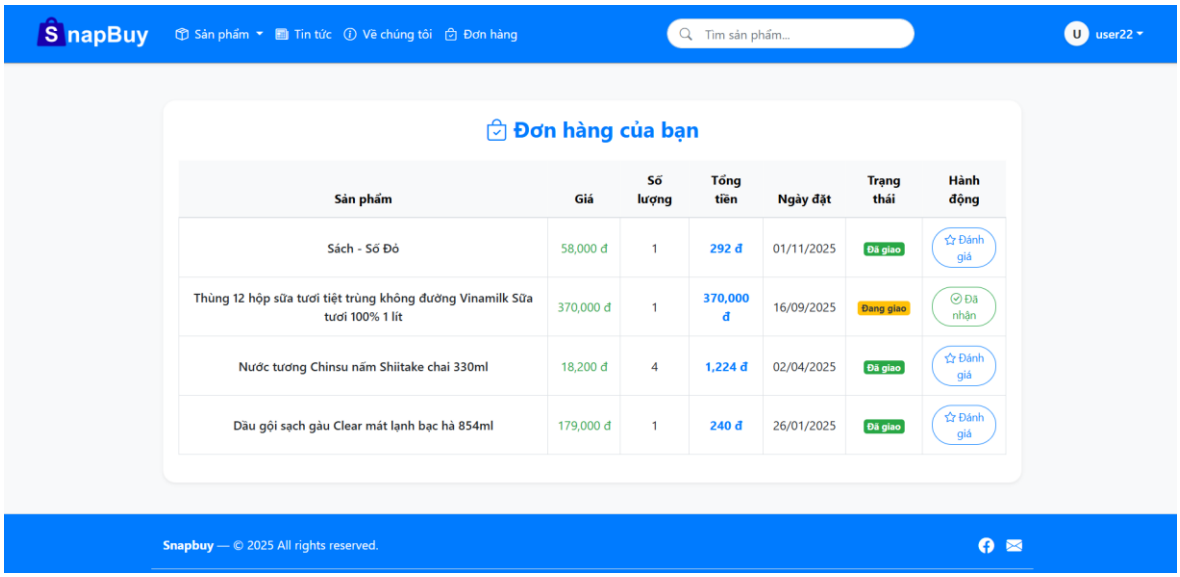

Hình 27. Giao Diện Đơn Hàng Đã Mua

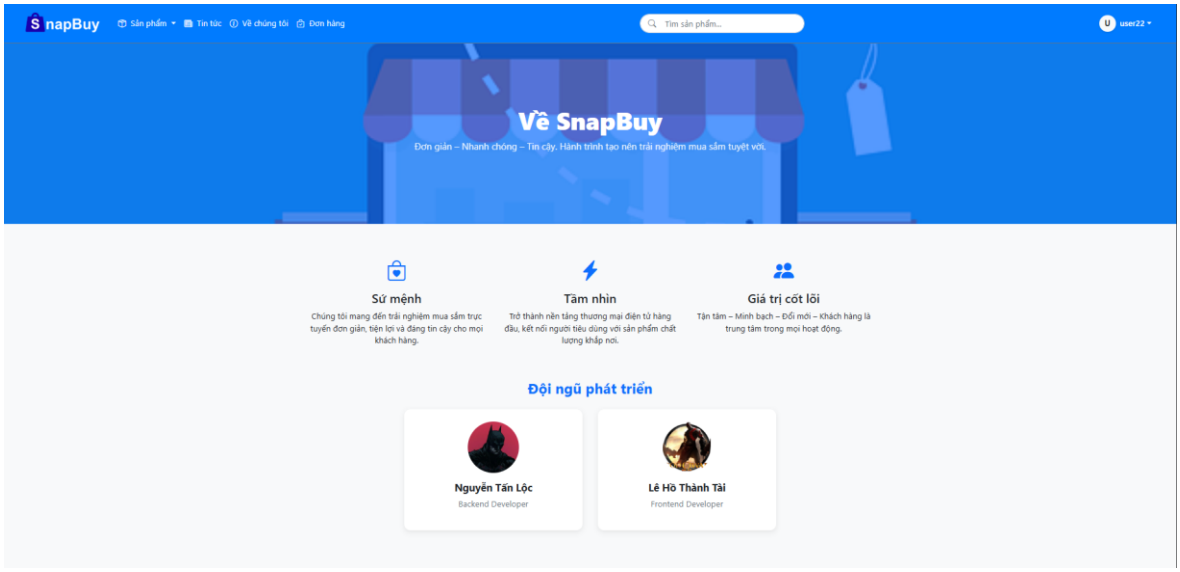

Hình 28. Giao Diện Trang Về Chúng Tôi

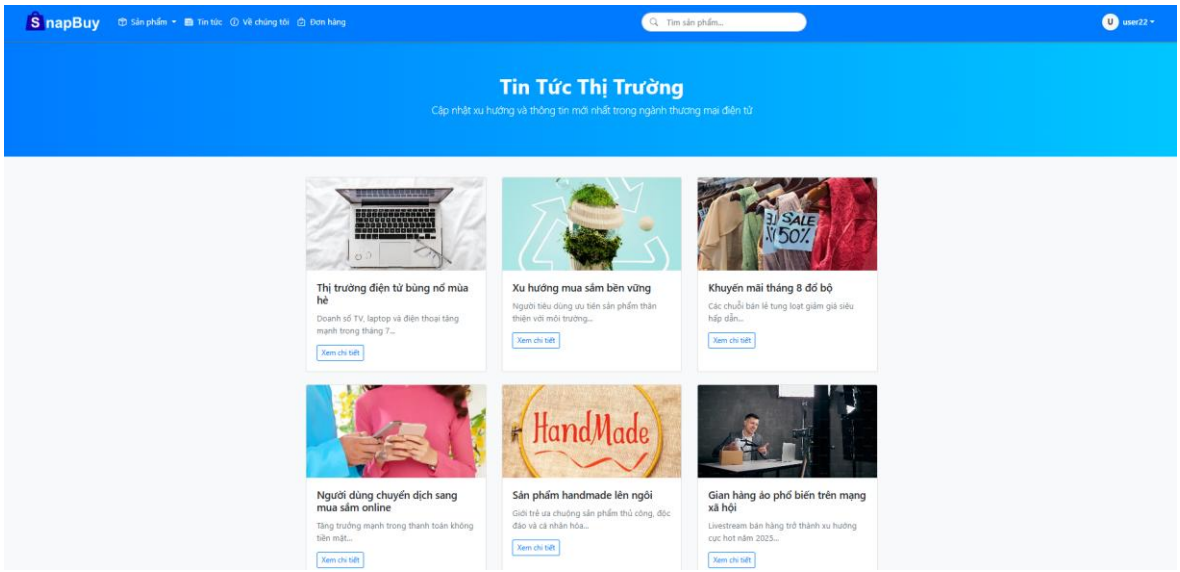

Hình 29. Giao Diện Trang Tin Tức

4.6.2 Người dùng quản trị

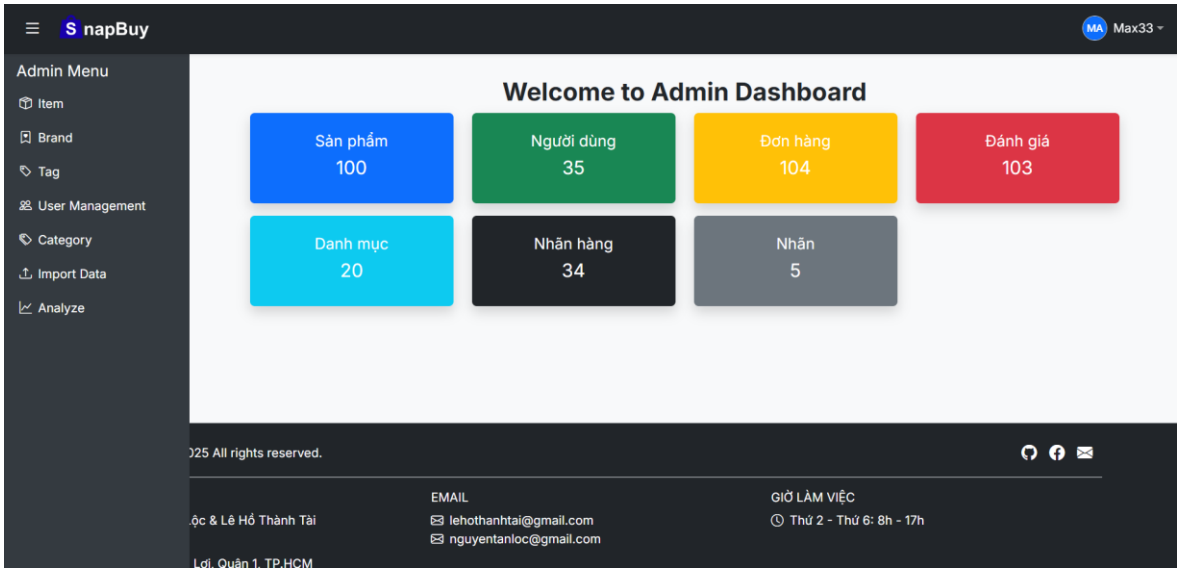

Hình 30. Giao Diện Dashboard Cho Admin

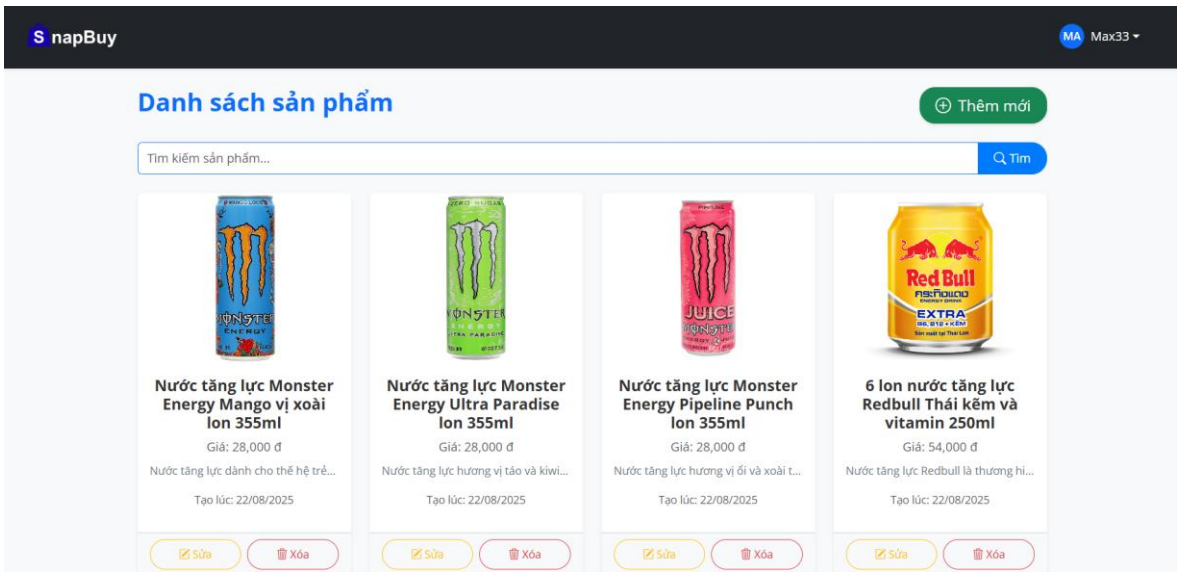

Hình 31. Giao Diện Quản Lý Sản Phẩm

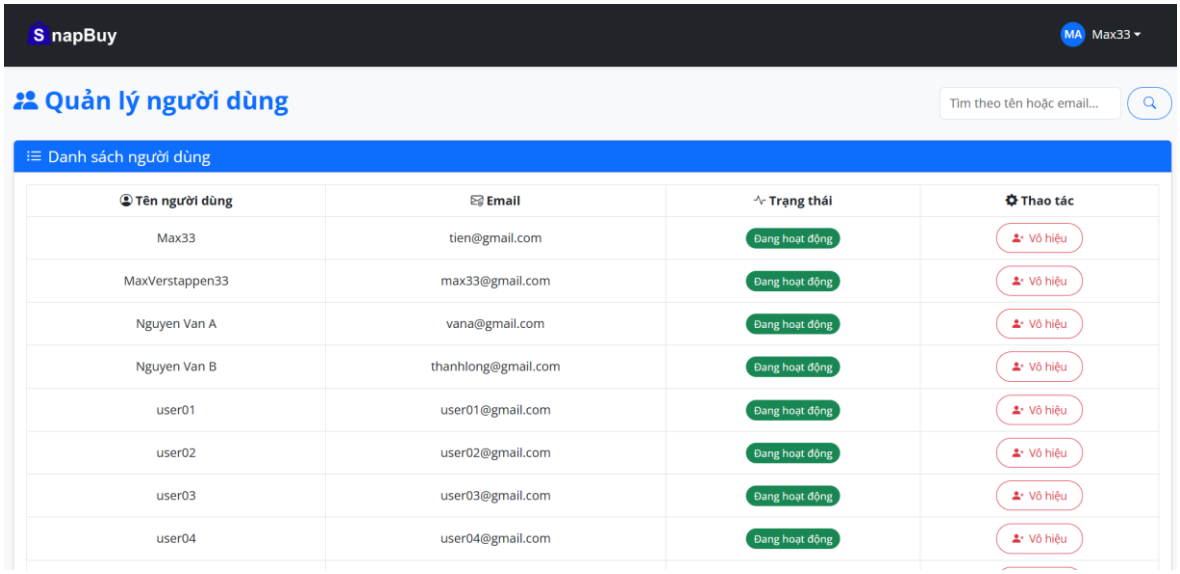

Hình 32. Giao Diện Quản Lý Người Dùng

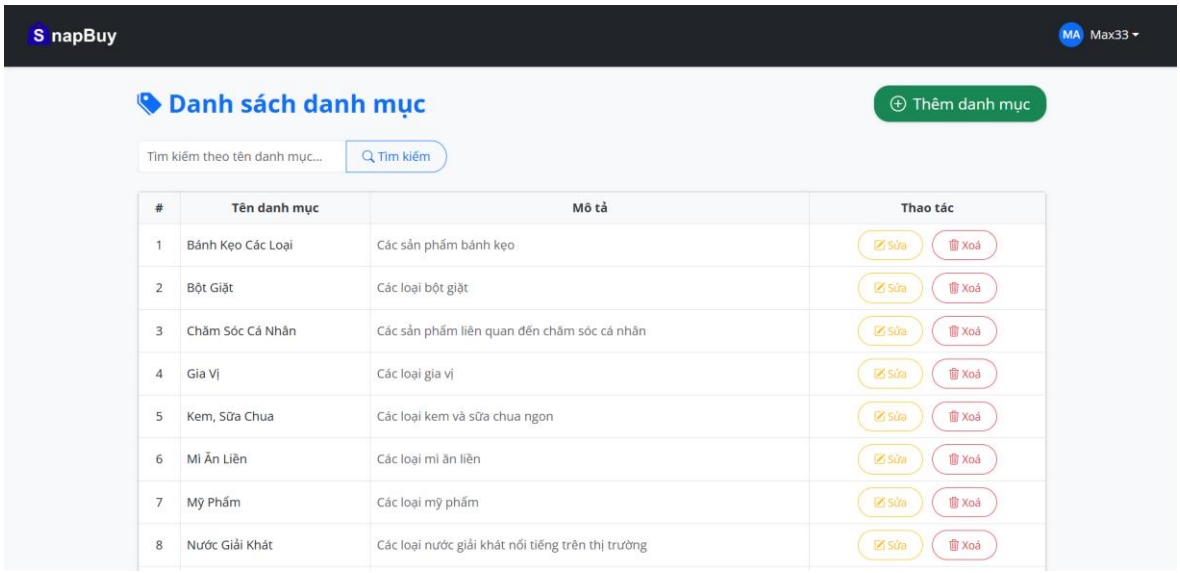

Hình 33. Giao Diện Quản Lý Danh Mục

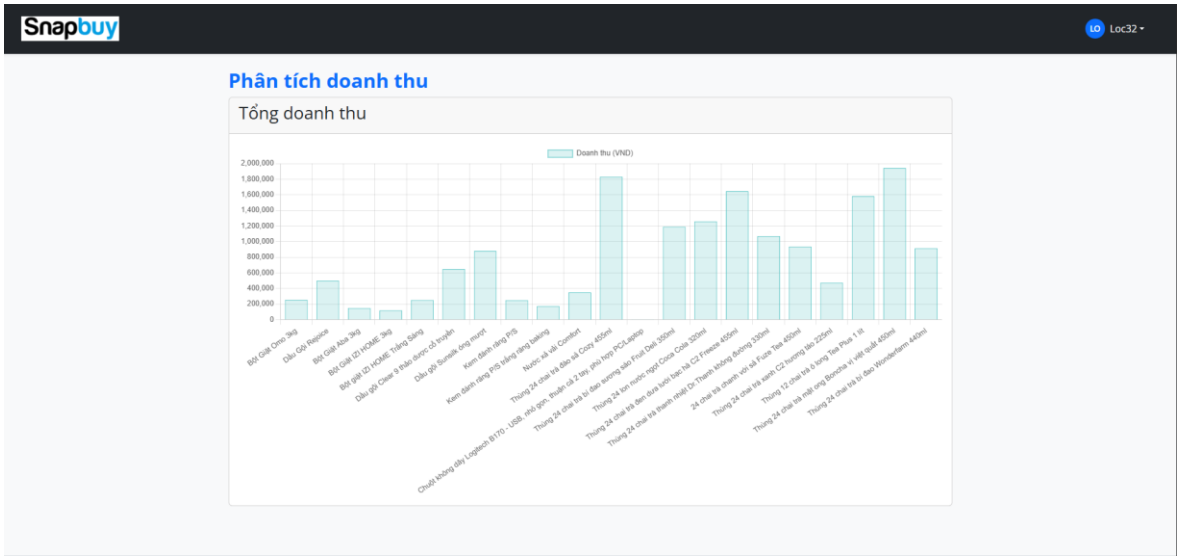

Hình 34. Giao Diện Thống Kê Doanh Thu

Chương 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1.1 Tóm tắt kết quả đạt được

Trong quá trình thực hiện đồ án, hệ thống gợi ý sản phẩm đã được xây dựng thành công trên nền tảng web thương mại điện tử mô phỏng. Ba mô hình lọc đề xuất được áp dụng bao gồm:

- Mô hình lọc cộng tác sử dụng Surprise (SVD): khai thác lịch sử đánh giá sản phẩm của người dùng.
- Mô hình content-based theo thuộc tính sản phẩm: dựa trên thông tin danh mục và nhãn hàng để tính toán độ tương đồng giữa các sản phẩm.
- Mô hình content-based theo hành vi người dùng: dựa trên dữ liệu tương tác thực tế như lượt xem và click sản phẩm.

Các mô hình được huấn luyện từ dữ liệu mô phỏng và tích hợp thành công vào hệ thống backend Flask. Giao diện web có khả năng hiển thị các gợi ý phù hợp theo từng người dùng. Việc đánh giá hiệu suất của mô hình bằng chỉ số như RMSE cho thấy mô hình đề xuất đã mang lại hiệu quả tương đối tốt.

5.1.2 Hạn chế của nghiên cứu

Mặc dù hệ thống đã hoạt động ổn định, nhưng vẫn còn một số điểm hạn chế:

- Dữ liệu huấn luyện còn hạn chế về số lượng và chưa phản ánh đầy đủ hành vi người dùng ngoài đời thực.

- Mô hình lọc cộng tác yêu cầu người dùng phải có lịch sử đánh giá, do đó còn hạn chế trong trường hợp người dùng mới (cold - start problem).
- Mô hình hiện tại chưa tích hợp cơ chế đánh giá theo phiên sử dụng (session-based), do đó độ cá nhân hóa theo ngữ cảnh còn chưa cao.
- Việc đánh giá mô hình chỉ dừng lại ở mô phỏng, chưa triển khai với dữ liệu thật từ một hệ thống TMĐT thực tế.
- Chưa đánh giá được 2 mô hình Content-Based bằng các chỉ số chuyên nghiệp như Precision@5, Recall@5 và F1-score.

5.1.3 Hướng phát triển

Trong tương lai, hệ thống có thể được cải tiến và phát triển theo các hướng sau:

- Tăng số lượng và tính đa dạng của dữ liệu huấn luyện, bao gồm lịch sử mua hàng thực tế và các loại tương tác khác như bỏ vào giỏ hàng, đánh giá văn bản,...
- Tích hợp thêm các mô hình hiện đại hơn như session-based recommendation, Deep Learning (GRU4Rec, SASRec), hoặc mô hình kết hợp giữa collaborative filtering và content-based.
- Phát triển tính năng gợi ý theo ngữ cảnh như thời gian trong ngày, địa điểm, hoặc các sự kiện khuyến mãi đang diễn ra.
- Tích hợp tính năng retrain lại mô hình định kỳ dựa trên dữ liệu từ chính hệ thống.
- Đánh giá cụ thể cho 2 mô hình còn lại bằng các chỉ số để từ đó đưa ra so sánh giữa 3 mô hình đã triển khai. Dựa trên so sánh này mà về sau khi tích hợp mô hình vào dự án thật ta sẽ chọn được mô hình tốt, phù hợp với từng hệ thống.

Tài liệu tham khảo

[1] – Học Máy https://vi.wikipedia.org/wiki/H%E1%BB%8Dc_m%C3%A1y

[2] – Flask Course – Python Web Application Development

https://www.youtube.com/watch?v=Qr4QMBUPxWo&t=16456s

[3] – Trí Tuệ Nhân Tạo

https://vi.wikipedia.org/wiki/Tr%C3%AD_tu%E1%BB%87_nh%C3%A2n_t%E1%BA%A1o

[4] – Singular Values Decomposition và một số ứng dụng

https://viblo.asia/p/handbook-singular-values-decomposition-va-mot-so-ung-dung-yMnKMOoml7P

[5] – Đánh giá model trong Machine Learing

https://viblo.asia/p/danh-gia-model-trong-machine-learing-RnB5pAq7KPG